Universidad Nacional Autónoma de México

Facultad de Ciencias

Almacenes y Minería de Datos

Tarea 01

Profesora: Jessica Santizo Galicia

Ayudantes: Diego Antonio Villalba González, Ares Gael Castro Romero

Integrantes del Equipo:

Brenda Jiménez Ruiz

Irany Solano Marcial

Juan Luis Peña Mata

Fecha de entrega:

25 de febrero de 2026, a más tardar a las 23:59

1. Conceptos

1. Da un ejemplo de Almacén de Datos (de acuerdo con tus intereses, no repetir lo visto en clase) y explica cómo se cumple la definición en tu ejemplo. Incluye:

   - Orientación a temas
   - Integración de datos
   - Variabilidad en el tiempo
   - No volatilidad

   Almacén de Datos: Videojuego League of Legends

   Riot Games recopila datos de millones de partidas diarias provenientes de distintas fuentes: servidores de juego por región (NA, LAN, EUW, LCK), el sistema de ranked, la tienda de contenido cosmético y la plataforma de eSports profesional. Para analizar el rendimiento de campeones, el comportamiento de jugadores por temporada y apoyar decisiones estratégicas sobre balance del juego y organización de torneos, se construye un **Almacén de Datos**.

   Subject-Oriented (Orientación a temas)
   El almacén se organiza en torno a temas de interés para los analistas de Riot Games, como rendimiento de campeones, progresión de jugadores en ranked y estadísticas de la escena competitiva, y no en torno a las aplicaciones que operan el juego.

   Por ejemplo, el almacén debería organizarse por:

   Campeón, Jugador, Partida, Torneo

   Y no por los sistemas que lo generan:

   Sistema de matchmaking, Sistema de tienda, Sistema de ranked

   Integrated (Integración de datos)

   Debe integrar información proveniente de diferentes sistemas que usan convenciones distintas. Por ejemplo, la región de un jugador puede representarse de formas distintas según la fuente:

   El servidor de juego guarda "LAN", el sistema de torneos guarda Latin America North y la tienda guarda "la2".

   Es necesario transformar los datos para seguir una convención única en el almacén, guardando la información con consistencia.

Time-Variant (Variante en el tiempo)

Proporciona una perspectiva histórica del juego a lo largo de temporadas y parches. Los datos no se actualizan ni se sobreescriben; si hay información nueva (por ejemplo, las estadísticas del parche 14.5), se agrega al almacén conservando los datos del parche 14.4. Esto permite analizar la evolución del balance de un campeón a lo largo del tiempo y detectar tendencias, como qué rol domina el meta en cada temporada.

Non-Volatile (No volátil)

El almacén es un repositorio físicamente separado de los sistemas operacionales de Riot Games. Solo se realizan dos operaciones principales: carga de datos (al finalizar cada parche o temporada) y acceso o consulta de datos (para análisis). No se realizan actualizaciones frecuentes, eliminaciones ni operaciones transaccionales. Si un campeón es eliminado del juego, su historial de partidas permanece intacto en el almacén.

2. Explica con tus propias palabras la diferencia entre un Almacén de Datos y:

   - Una base de datos transaccional

     La diferencia fundamental entre un **Almacén de Datos (Data Warehouse)** y una Base de Datos **Transaccional (OLTP)** radica en que la primera está diseñada para analizar el negocio, mientras que la segunda está hecha para operarlo.

Aspecto	**Base de Datos Transaccional (OLTP)**	**Almacén de Datos (DW)**
Propósito y Función	Su objetivo es la ejecución eficiente de las operaciones del día a día. Se utiliza para tareas como registrar una venta, agendar una cita o actualizar la información de un paciente	Su función es servir de apoyo al proceso de toma de decisiones de la dirección. Se usa para entender el negocio mediante reportes, análisis de tendencias y comparaciones entre periodos de tiempo.
Tipo de Operaciones y Procesamiento	Realiza muchas operaciones pequeñas y rápidas (inserciones, actualizaciones y eliminaciones de registros individuales) con muchos usuarios concurrentes.	Se caracteriza por la carga masiva de datos y el acceso o consulta de los mismos. Las consultas suelen ser pocas pero grandes y pesadas, ya que deben procesar miles o millones de filas para generar un resultado.

   - Un esquema estrella

     La diferencia principal es que un **Almacén de Datos (Data Warehouse)** es el sistema o entorno arquitectónico completo, mientras que un **Esquema Estrella** es

una forma específica de organizar los datos (un modelo lógico y físico) dentro de ese almacén.

Aspecto	Almacén de Datos (DW)	Esquema Estrella
Estructura y Composición	Incluye toda la infraestructura, desde los procesos de extracción (ETL), el área de *staging*, hasta el almacenamiento y las herramientas de acceso. Puede contener múltiples tipos de estructuras, no solo esquemas estrella.	Se caracteriza por tener una estructura de tablas de hechos rodeada por tablas de dimensiones.

- Un cubo OLAP

  La diferencia fundamental es que un **Almacén de Datos (Data Warehouse)** es la infraestructura arquitectónica que sirve como base de datos integrada y global, mientras que un **Cubo OLAP** es una tecnología específica de procesamiento (a menudo parte de un Data Mart) optimizada para el análisis rápido y multidimensional.

Aspecto	Almacén de Datos (DW)	Cubo OLAP (Procesamiento Analítico en Línea)
Relación y Propósito	Es el cimiento o la base de datos central de la corporación que almacena datos granulares y detallados recolectados de los sistemas operacionales. Su fin es proporcionar una única versión de la verdad integrada y consistente.	Es una estructura de datos (frecuentemente alimentada por el DW) diseñada para que los analistas puedan realizar consultas complejas, rebanar y picar (slice and dice) los datos y explorar relaciones entre resúmenes y detalles de forma instantánea.

- Un Data Lake

Aspecto	Almacén de Datos (DW)	Data Lake
Estructura de los datos	Almacena datos estructurados y preprocesados	Puede almacenar datos en cualquier formato, desde crudo hasta semi-estructurado o no estructurado.
Flexibilidad	Suelen tener una estructura rígida y definida, lo que los hace menos flexibles para adaptarse a cambios en los requisitos de análisis.	Ofrecen una mayor flexibilidad ya que pueden almacenar datos en su forma original, lo que facilita la exploración y el análisis de datos no estructurados.

2. Escenario

El Instituto de Matemáticas de la Universidad Nacional Autónoma de México desarrolla y analiza modelos matemáticos mediante simulaciones numéricas, orientadas al estudio de ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos y métodos numéricos. Cada ejecución de simulación genera información distribuida que se encuentra en registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos computacionales. Actualmente, esta información no está integrada, lo que dificulta el análisis histórico y la toma de decisiones estratégicas. Por lo anterior, el Instituto te contrata para diseñar un Almacén de Datos que permita analizar el uso de recursos, el comportamiento de las simulaciones y su evolución a lo largo del tiempo.

3. Resuelve los siguientes ejercicios

1. Menciona qué beneficios tendrá utilizar un Almacén de Datos en un entorno de cómputo científico. Justifica.

   El poder analizar la eficiencia de las simulaciones y administrar los recursos computacionales con mayor eficiencia son los mayores beneficios, esto permitiría una posible expansionan del sistema analizando las necesidades de las simulaciones, ademas, el tener un registro histórico permitirá reproducir las simulaciones, en el ámbito científico esto es muy importante ya que una simulación se podría repetir para corroborar el resultado.

2. Indica qué usuarios utilizarían este Almacén de Datos y con qué propósito. Justifica.

   Los usuarios principales son los investigadores del Instituto, puesto que ellos son los que realizan las simulaciones, con este almacén podrían contrastar sus resultados con otras simulaciones o verificar que estas son consistentes.

   También están los administradores de los sistemas puesto que el Almacén de Datos les ayudaría a repartir los recursos de una mejor forma.

   Por otro lado algunos estudiantes también podrían utilizarlo analizando resultados históricos como proyecto de tesis.

3. Escribe al menos cinco preguntas que el Instituto desearía responder en términos de análisis.

   - ¿Qué tipo de simulaciones requieren más recursos computacionales? Para asignarles mas recursos desde el inicio y no cuando los requieran.
   - ¿Qué tipo de simulaciones falla con mas frecuencia? Para buscar optimizaciones a simulaciones concretas.
   - ¿En que periodos de tiempo se usan mas recursos computacionales? Para aplicar restricciones durante esos periodos o para implementar un mejor sistema de agenda para el uso de los recursos.
   - ¿Qué área de investigación realiza mas simulaciones? Para asignarles mas recursos al área.
   - ¿En los últimos 5 años como ha aumentado el uso de recursos de computo? Para considerar mejorar la infraestructura de los sistemas.

4. Describe qué datos históricos almacenaría el Data Warehouse del Instituto de Matemáticas y qué decisiones estratégicas apoyaría.

   Podemos tomar los siguientes datos históricos:

   - Tiempo de ejecución.
   - Memoria usada.
   - Número de procesos.
   - Número de errores.

   Estos datos podrían señalar una falta de poder computacional, por lo que podría respaldar la inversión en una mejoría del sistema computacional, también podría apoyar políticas de uso para sistema en general, descendencia de simulaciones ineficientes.

5. Define el hecho principal del modelo multidimensional.

   El hecho principal es una ejecución de una simulación, puesto que el escenario nos pide poder analizar el uso de recursos suponiendo que puede ser calculado numéricamente, el comportamiento de las simulaciones, pensando que una simulación puede repetirse y obtener resultados diferentes, y su evolución a lo largo del tiempo.

6. Explica qué representa una fila en la tabla de hechos y da cinco ejemplos. Se consideran los siguientes niveles de granularidad para el hecho Ejecución de Simulación:

   - Una fila por simulación científica
   - Una fila por ejecución completa de simulación
   - Una fila por paso iterativo interno

7. Selecciona la granularidad adecuada y justifica por qué es preferible a las demás.

   Proponemos la granularidad como una fila por ejecución completa de simulación debido a que sobre todo si se desean analizar procesos estocásticos, se pueden obtener resultados

que difieran aun tendiente los mismos parámetros por simulación, esto hace posible que se pueda analizar que tanto puede diferir el resultado de una ejecución.

La granularidad por una fila por simulación científica nos dejaría con panorama mas general, puesto que el análisis podría llevarse a cabo entre simulaciones diferentes pero que comparten un mismo objetivo.

Consideramos que tomar una fila por paso iterativo interno no es adecuado ya que las simulaciones podrían diferir mucho en el número de iteraciones necesarias para ejecutarse, haciendo complicado el punto de comparación entre simulaciones.

8. Explica cuándo sería adecuada una granularidad alta y cuándo una baja, incluyendo sus ventajas y desventajas.

   Se puede usar una granularidad baja si se desea optimizar los recursos computacionales así en lugar de analizar cada ejecución se ven que tipos de simulaciones requieren más o menos recursos, dándole prioridad a simulaciones de un tipo especifico, sin embargo esto causaría que el análisis de ejecuciones tenga menos detalle.

   La granularidad alta podría indicarnos que iteraciones gastan mas recursos computacionales o tardan mas tiempo, esto podría ser útil para poder optimizar las simulaciones, sin embargo, cada ejecución de una simulación podría tener miles de iteraciones en las que no exista un cambio significativo, ocupando mas espacio.

9. Dibuja el esquema estrella correspondiente al escenario. Considera que:

   a) Debe haber al menos cuatro medidas numéricas.

   b) Deben definirse al menos cinco dimensiones, incluidas Tiempo y Simulación.

   c) Deben indicarse los atributos relevantes de cada dimensión.

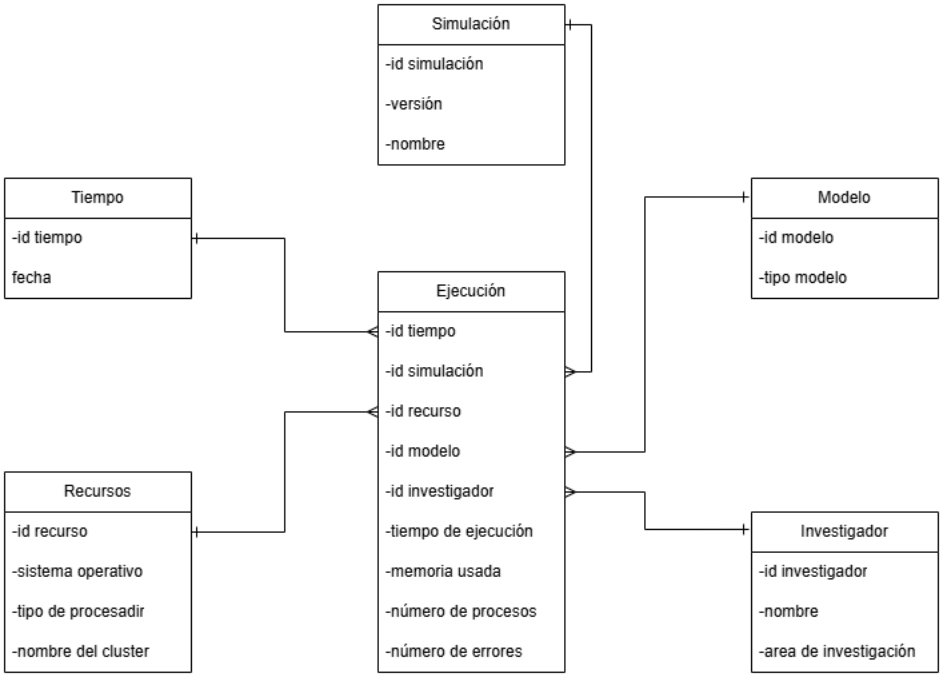

10. Describe las capas de la arquitectura de un Almacén de Datos.

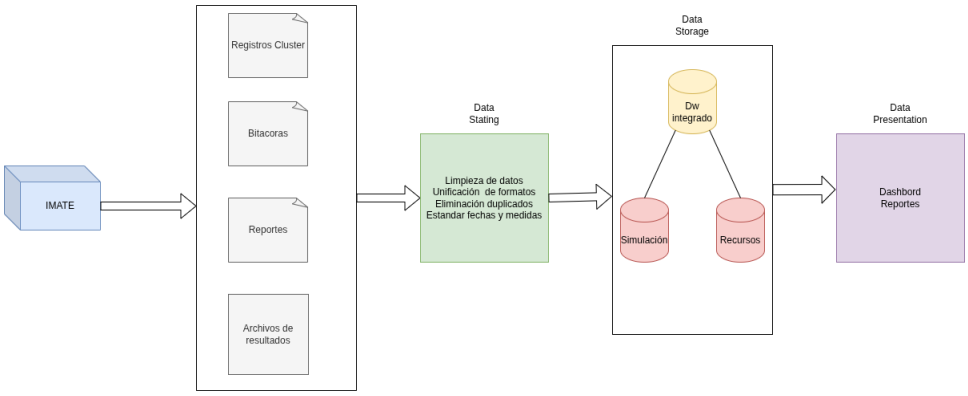

- Data Source: Son los sistemas o bases de datos de donde se toma toda la información.
- Data Staging: Es la capa donde se procesan los datos, estos pasan por una limpieza y se transforman a un formato estándar.
- Data Storage: Es la capa donde se guardan los datos después de ser procesados y estandarizados.
- Data Presentation: Es la capa donde hay herramientas que permiten a los usuarios realizar el análisis haciendo consultas o realizando reportes.

11. Explica el rol de cada capa en el contexto del cómputo científico.

- Data Source: Son los registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos computacionales.
- Data Staging: Se estandarizan los datos obtenidos mediante Scripts.
- Data Storage: Es donde se guardan los datos de todas las ejecuciones.
- Data Presentation: Se generan reportes sobre el uso de recursos computacionales, o reportes sobre el rendimiento de las simulaciones.

12. Indica dónde se implementa el modelo estrella. El modelo estrella se implementa durante la capa de Data Storage ya que el modelo estrella se encarga de definir como se guardaran los datos en el Data Warehouse.

4. Detección de errores

Plantea y describe dos errores de diseño posibles en un Almacén de Datos para este escenario. Los errores no deben impedir la ejecución de consultas, pero sí producir resultados incorrectos o engañosos.

Para cada error, indica:

- Un ejemplo de consulta donde el problema sea evidente.
- Cómo corregirías el error (ETL o modelo). Escribe detalladamente los pasos a seguir, así como tu solución.

Error 1: Fechas sin estandarizar entre fuentes (problema de integración)

Descripción: Los registros del clúster guardan las fechas en formato DD/MM/YYYY (por ejemplo 15/03/2024), mientras que las bitácoras de ejecución las guardan en formato Unix timestamp (por ejemplo 1710460800). El ETL carga ambas fuentes sin convertirlas a un formato único, generando registros con fechas inconsistentes o nulas en la dimensión Tiempo.

Consulta donde el problema es evidente:

```sql
SELECT t.fecha, COUNT(*) as total_ejecuciones
FROM hechos_ejecucion h
JOIN dim_tiempo t ON h.id_tiempo = t.id_tiempo
WHERE t.fecha BETWEEN '2024-01-01' AND '2024-12-31'
GROUP BY t.fecha;
```

Esta consulta excluiría silenciosamente todas las ejecuciones cuyas fechas vinieron de las bitácoras en formato Unix y no se convirtieron correctamente, haciendo que el conteo histórico aparezca incompleto sin ningún mensaje de error.

Cómo corregirlo:
En el ETL, agregar un paso de estandarización de fechas antes de poblar la dimensión Tiempo:

1. Identificar el formato de fecha de cada fuente: DD/MM/YYYY para registros del clúster y Unix timestamp para bitácoras.
2. En la transformación, convertir ambos formatos a un formato único YYYY-MM-DD:
   - Para DD/MM/YYYY: reordenar los componentes.
   - Para Unix timestamp: aplicar la conversión correspondiente, por ejemplo `FROM_UNIXTIME()` en MySQL.
3. Validar que ningún registro quede con fecha nula o fuera de rango antes de la carga.
4. Agregar una regla de calidad en el ETL que rechace o marque cualquier registro cuya fecha no pueda convertirse, enviándolo a una tabla de registros rechazados para revisión manual.

Error 2: Valores nulos en medidas de la tabla de hechos

Descripción: Algunas simulaciones antiguas no registraban el número de procesos utilizados, por lo que ese campo llega como nulo al DW. El ETL no detecta ni reemplaza estos nulos, y quedan almacenados directamente en la tabla de hechos. Las consultas funcionan, pero los promedios y sumas que incluyen ese campo ignoran silenciosamente esas filas, produciendo resultados engañosos.

Consulta donde el problema es evidente:

```sql
SELECT AVG(numero_procesos) as promedio_procesos
FROM hechos_ejecucion;
```

SQL ignora los nulos al calcular el promedio, así que el resultado parece válido pero en realidad solo considera una parte de las ejecuciones, haciendo que el promedio parezca más alto o más bajo de lo real.

Cómo corregirlo:

1. En el ETL, agregar una regla de transformación que detecte valores nulos en las medidas numéricas.
2. Reemplazar los nulos por un valor acordado con el equipo, por ejemplo 0 si no hubo procesos registrados, o el promedio histórico de esa medida.
3. Documentar en el DW qué valor se usa como sustituto para que los analistas lo tengan en cuenta al interpretar los resultados.