Personas Desaparecidas y No Localizadas en México

Análisis Exploratorio de Datos — RNPDNO 2023

Brenda Jiménez Ruiz Irany Solano Marcial
Juan Luis Peña Mata

26 de marzo de 2026

Tabla de contenidos

Inicio 1
- 0.1 Resumen ejecutivo . . . 1
  - 0.1.1 Fuentes oficiales . . . 1
  - 0.1.2 Nota metodológica . . . 1
  - 0.1.3 Estructura del reporte . . . 1

1 Metodología 3
- 1.1 BBVA — Irany Solano Marcial . . . 3
  - 1.1.1 Herramientas principales . . . 3
  - 1.1.2 Aplicaciones concretas . . . 3
- 1.2 Netflix — Brenda Jiménez Ruiz . . . 3
- 1.3 Google — Juan Luis Peña Mata . . . 4

2 Objetivo 5
- 2.1 Objetivo general . . . 5
- 2.2 Preguntas de análisis . . . 5
- 2.3 Criterios de éxito . . . 5

3 Dataset 6
- 3.1 Descripción general . . . 6
- 3.2 Diccionario de datos . . . 6
- 3.3 Limpieza de datos . . . 7
  - 3.3.1 Nulos justificados en el dataset limpio . . . 8
- 3.4 Normalización . . . 8
  - 3.4.1 Correcciones ortográficas en Nacionalidad . . . 8
  - 3.4.2 Validación de fechas . . . 8

4 CRISP-DM 9
- 4.1 Fases aplicadas . . . 9
- 4.2 Fase 4 — Técnicas sugeridas . . . 9
  - 4.2.1 Clustering (HDBSCAN o K-Means) . . . 9
  - 4.2.2 Series de tiempo (Prophet o ARIMA) . . . 9
  - 4.2.3 Clasificación supervisada . . . 10

5 Análisis Exploratorio de Datos (EDA) 11
- 5.1 Medidas de localización . . . 11
- 5.2 Medidas de variabilidad . . . 11
- 5.3 Medidas de heterogeneidad . . . 12
- 5.4 Medidas de concentración . . . 12

6 Correlación **13**
6.1 Matriz de correlación . . . 13
6.2 Interpretación . . . 13

7 Hallazgos **15**
7.1 H1 — Tamaulipas concentra el mayor número . . . 15
7.2 H2 — Hombres: 3 de cada 4 registros . . . 19
7.3 H3 — Jóvenes 15–30: grupo más vulnerable . . . 19
7.4 H4 — Incremento sostenido desde 2006 . . . 19
7.5 H5 — Fiscalías estatales concentran reportes . . . 19
7.6 H6 — 87.4 % de nacionalidad mexicana . . . 19
7.7 H7 — 32.1 % de registros protegidos . . . 19
7.8 H8 — Alta variabilidad en edad . . . 19

8 Limitaciones **20**
8.1 Calidad de los datos y sesgos . . . 20
8.1.1 Calidad de los datos . . . 20
8.1.2 Sesgos . . . 20
8.2 Variables faltantes y decisiones . . . 20
8.2.1 Variables faltantes . . . 20
8.2.2 Decisiones de limpieza documentadas . . . 21

9 Conclusión **22**
9.1 Síntesis de hallazgos . . . 22
9.1.1 Dimensión geográfica . . . 22
9.1.2 Dimensión demográfica . . . 22
9.1.3 Dimensión temporal e institucional . . . 22
9.1.4 Perspectivas futuras . . . 23

Referencias **24**

Inicio

0.1. Resumen ejecutivo

Este reporte presenta el análisis exploratorio del dataset **RNPDNO-22-08-2023.csv**, publicado por la **Comisión Nacional de Búsqueda de Personas (CNB)** de la Secretaría de Gobernación.

Indicador	Valor
Total de registros (dataset original)	116,945
Registros con datos completos	79,488
Registros protegidos	37,460
Periodo cubierto	1968 – 2023

0.1.1. Fuentes oficiales

- RNPDNO — Versión Estadística
- Observatorio sobre Desaparición e Impunidad — UNAM
- ¿A dónde van los desaparecidos?

0.1.2. Nota metodológica

El dataset contiene ~**37,460 registros protegidos** (etiquetados como *ELIMINADO*), correspondientes a casos cuya identidad fue resguardada conforme a la *Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados*. Estos registros **no son errores** — representan casos reales y se documentan como una limitación estructural del análisis.

0.1.3. Estructura del reporte

Capítulo	Contenido
I. Metodología	Empresa y metodología de Minería de Datos por integrante
II. Objetivo	Preguntas de análisis y criterios de éxito
III. Dataset	Descripción, diccionario, limpieza y normalización
IV. CRISP-DM	Aplicación de la metodología al caso
V. EDA	Medidas descriptivas y visualizaciones

Capítulo	Contenido
VI. Correlación	Matriz de correlación (heatmap)
VII. Hallazgos	8 hallazgos principales con evidencia gráfica
VIII. Limitaciones	Calidad, sesgos, variables faltantes
IX. Conclusión	Síntesis y perspectivas futuras

1 Metodología

1.1. BBVA — Irany Solano Marcial

BBVA es una de las instituciones financieras más grandes de España y América Latina, con presencia activa en México. Su área de datos, **BBVA Data & Analytics (D&A)**, ha documentado públicamente su enfoque metodológico para proyectos de minería de datos.

En BBVA D&A los proyectos heredan características de CRISP-DM, pero no lo aplican de forma rígida. Con sus proyectos aumentando en número y diversidad, el equipo desarrolló un flujo de trabajo integral propio para encajar mejor en **prácticas ágiles**.

1.1.1. Herramientas principales

Categoría	Herramienta
Data Discovery	Amundsen
Exploración	TensorFlow Data Validation, InspectDF
Features	FeatureTOOLS, Ludwig, client2vec

1.1.2. Aplicaciones concretas

- Detección de perfiles de clientes fraudulentos
- Estimación de probabilidad de abandono (churn)
- Identificación de patrones de consumo para recomendación de productos financieros

Fuente: José Antonio Rodríguez Serrano. *Acelerar el flujo de trabajo en Ciencia de Datos.* BBVA AI Factory, mayo 2025.

1.2. Netflix — Brenda Jiménez Ruiz

Netflix es una plataforma de entretenimiento con más de 300 millones de suscriptores. Su enfoque se distingue por estar centrado en la **experimentación continua**.

A diferencia de metodologías estándar como CRISP-DM, Netflix desarrolló su propio **proceso iterativo basado en el método científico**. Los científicos de datos participan en todo el ciclo de vida del proyecto:

- Exploración de datos e ideación
- Diseño y ejecución de pruebas

- Análisis de resultados
- Síntesis de aprendizajes para informar decisiones

El pilar técnico central es su plataforma de experimentación propia **ABlaze**, que soporta más de 3,000 proyectos de IA y ML, ejecutando cientos de millones de trabajos de cómputo y gestionando decenas de petabytes de modelos y artefactos.

Fuente: Martin Tingley et al. *Experimentation is a major focus of Data Science across Netflix*. Netflix Tech Blog, enero 2022.

1.3. Google — Juan Luis Peña Mata

Google es pionera en el uso de machine learning a escala masiva. Su metodología reconoce que los proyectos de ML son **fundamentalmente distintos** a los proyectos de software tradicionales — no lineales y con grados variables de incertidumbre.

En lugar de un plan rígido, Google promueve una **mentalidad experimental** documentada en *Rules of Machine Learning*, que organiza el desarrollo en tres fases:

Fase	Descripción
1. Infraestructura	Construcción de pipeline y primeros modelos
2. Iteración	Lanzamiento, nuevas características, evaluación de modelos
3. Optimización	Mejoras avanzadas al alcanzar plateau de rendimiento

A nivel de infraestructura, Google centraliza sus proyectos en **Vertex AI**, plataforma unificada que combina BigQuery con herramientas de MLOps.

Fuente: Google Developers. *Planificación de proyectos de AA*. https://developers.google.com/machine-learning/managing-ml-projects/planning?hl=es-419

---

2 Objetivo

2.1. Objetivo general

El presente reporte tiene como objetivo analizar el dataset **RNPDNO-22-08-2023.csv**, publicado por la **Comisión Nacional de Búsqueda de Personas (CNB)**, con la finalidad de identificar patrones temporales, geográficos y demográficos en los registros de personas desaparecidas y no localizadas en México. Los hallazgos están orientados a apoyar la toma de decisiones en materia de política pública y estrategias de búsqueda.

2.2. Preguntas de análisis

1. ¿Cuáles son las entidades federativas con mayor número de reportes de desaparición?
2. ¿Qué distribución por sexo presentan los registros de personas desaparecidas?
3. ¿Qué grupos de edad son los más afectados por las desapariciones reportadas?
4. ¿Existe una tendencia temporal en el número de desapariciones reportadas entre 2000 y 2023?
5. ¿Qué autoridades concentran el mayor volumen de reportes y qué implica esto institucionalmente?
6. ¿Cuál es la composición de nacionalidades en los registros y qué refleja sobre la dimensión migratoria del fenómeno?
7. ¿Qué proporción del dataset original fue eliminada por registros protegidos y cómo afecta al análisis?
8. ¿Qué nivel de variabilidad presenta la edad y qué grupos etarios concentran el mayor riesgo?

2.3. Criterios de éxito

El análisis se considerará exitoso si: (a) se identifican al menos 8 hallazgos sustentados con evidencia gráfica o tabular, (b) el dataset limpio presenta consistencia interna verificable, y (c) los resultados pueden ser comprendidos por tomadores de decisiones sin formación técnica.

---

3 Dataset

3.1. Descripción general

El dataset utilizado es el **Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO)**. En su estado original contiene **116,945 filas** y **11 columnas**, donde cada fila representa un reporte de desaparición de una persona.

Una misma persona puede tener más de un reporte. La columna *Consecutivo Reportes por Persona* actúa como identificador y solo aparece en el primer reporte de cada una. El dataset contiene **110,965 personas únicas** distribuidas en 116,945 reportes.

Característica	Valor
Filas (original)	116,945
Filas (limpio)	79,488
Columnas	11
Periodo cubierto	01/05/1968 al 20/08/2023
Personas únicas	77,259
Unidad de análisis	Un reporte individual de desaparición
Registros protegidos	37,460 (32.1 %)
Codificación	ISO-8859-1 (Latin-1)
Fuente	Comisión Nacional de Búsqueda de Personas (CNB)

3.2. Diccionario de datos

Variable	Descripción	Tipo de dato	Tipo estadístico
Consecutivo Reportes por Persona	Identificador de persona. Solo aparece en el primer reporte.	int64	Numérica discreta
Consecutivo Registro	Orden del reporte dentro de los registros de una misma persona.	int64	Numérica discreta
Nombre	Nombre(s) de pila. 5 nulos (0.01 %).	string	Categórica nominal
Primer Apellido	Primer apellido. 26 nulos (0.03 %).	string	Categórica nominal

Variable	Descripción	Tipo de dato	Tipo estadístico
Segundo Apellido	Segundo apellido. 1,449 nulos (1.82 %) — dato opcional.	string	Categórica nominal
Edad	Edad en años al momento de la desaparición. Rango: 1–100. Media: 31.8 años. 4,626 nulos (5.82 %).	float64	Numérica continua
Sexo	HOMBRE (75.6 %), MUJER (23.6 %), INDETERMINADO (0.8 %). Sin nulos.	string	Categórica nominal
Nacionalidad	Nacionalidad. MEXICANA (87.01 %). 2 nulos.	string	Categórica nominal
Fecha de desaparición	Fecha del evento. Rango: 1968–2023. 56,085 nulos (70.56 %) MNAR.	datetime64	Numérica continua
Entidad de desaparición	Estado de la República. 32 valores. Sin nulos. Más frecuente: Tamaulipas (14.2 %).	string	Categórica nominal
Autoridad que reportó	Institución que generó el reporte. Alta cardinalidad. Sin nulos.	string	Categórica nominal

3.3. Limpieza de datos

Consecutivo Reportes por Persona: Presentaba 5,980 nulos. Se aplicó *forward fill* para propagar el identificador hacia los reportes adicionales.

Registros ELIMINADO: Se identificaron 37,460 filas con datos protegidos (MNAR). Se eliminaron del dataset. **El dataset quedó con 79,488 filas.**

Fecha de desaparición: Con 70.56 % de faltantes MNAR, **no se imputó** por tres motivos: (1) cualquier método estaría inventando la mayoría de la columna; (2) los métodos estándar (KNN, imputación múltiple) asumen MAR, condición que no se cumple; (3) imputar con media/mediana introduciría sesgo grave en los análisis temporales.

Edad: 11 registros con valores > 100 años (máximo: 1,832) y 240 con valor $= 0$. Los 251 errores de captura fueron reemplazados por NaN. Rango válido: 1–100 años.

3.3.1. Nulos justificados en el dataset limpio

Columna	Nulos	%	Justificación
Segundo Apellido	1,449	1.82 %	Dato opcional
Edad	4,626	5.82 %	No registrado en el reporte
Fecha de desaparición	56,085	70.56 %	MNAR — ausencia estructural

3.4. Normalización

Todas las columnas de texto fueron convertidas a **mayúsculas** y se eliminaron espacios en blanco al inicio y al final de cada valor.

3.4.1. Correcciones ortográficas en Nacionalidad

Valor original	Valor corregido	Registros
HONDUREÑAO	HONDUREÑA	326 → unificados con 21 existentes = 347 total
SALVADORENA	SALVADOREÑA	—
BRASILENA	BRASILEÑA	—
BELICENA	BELICEÑA	—

3.4.2. Validación de fechas

- **Fechas futuras (> 2024):** 0 registros
- **Fechas anteriores a 1990:** 373 registros **conservados** — históricamente válidos (desapariciones durante la guerra sucia en México, década de 1970)
- Concentración de fechas en el primer día del mes: registros ingresados tardíamente con precisión de fecha limitada — característica del dato, no un error.

4 CRISP-DM

4.1. Fases aplicadas

La metodología **CRISP-DM** se aplicó de forma integral a lo largo de este reporte.

Fase	Actividades	Sección
1. Business Understanding	Objetivo, preguntas y criterios de éxito	Sección II
2. Data Understanding	Descripción, diccionario y EDA	Secciones III, V, VI
3. Data Preparation	Limpieza, conversión y normalización	Secciones III.3, III.4
4. Modelling	Técnicas sugeridas	Ver sección siguiente
5. Evaluation	Sesgos, limitaciones y calidad de datos	Sección VIII
6. Deployment	Reporte PDF, dashboard Quarto, CSV limpio	Sección IX

4.2. Fase 4 — Técnicas sugeridas

Aunque en este proyecto no se entrenaron modelos predictivos, se identifican las técnicas más adecuadas para un análisis posterior:

4.2.1. Clustering (HDBSCAN o K-Means)

Para identificar grupos de entidades con patrones similares de desaparición por edad, sexo y frecuencia temporal.

4.2.2. Series de tiempo (Prophet o ARIMA)

Para modelar la tendencia de reportes anuales y proyectar el comportamiento futuro, incorporando los efectos de cambios institucionales.

4.2.3. Clasificación supervisada

Si se dispusiera de la variable *localizado/no localizado*, podría predecirse el probable resultado de una búsqueda en función del perfil demográfico y geográfico del caso.

---

5 Análisis Exploratorio de Datos (EDA)

5.1. Medidas de localización

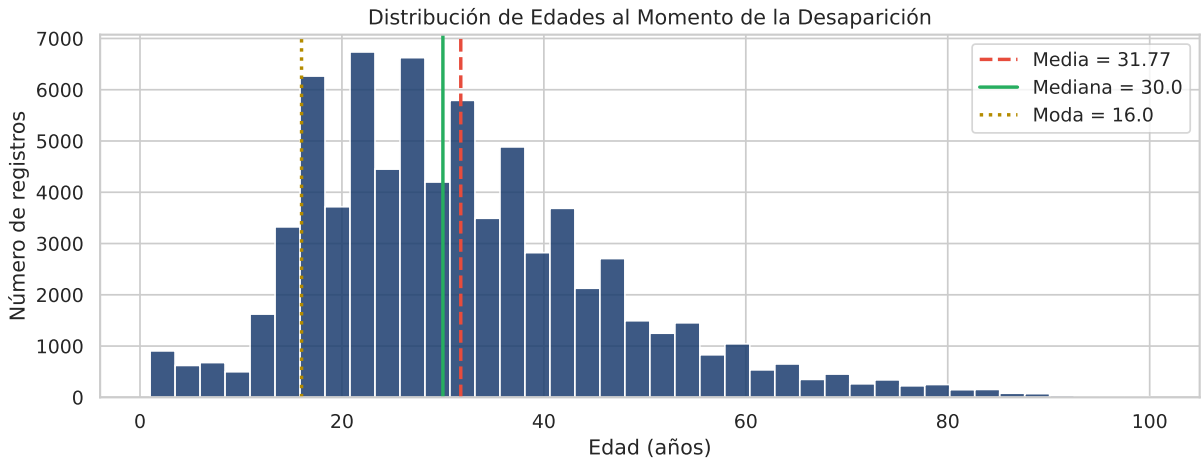

Figura 5.1: Distribución de edades al momento de la desaparición con medidas de tendencia central

5.2. Medidas de variabilidad

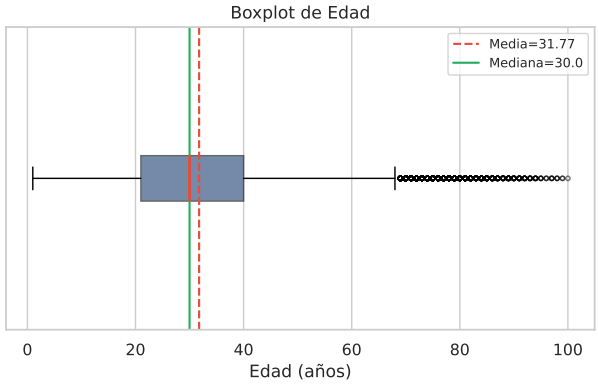

Medida	Valor
Desv. estándar	15.09
Varianza	227.57
Rango	99
IQR	19.0
Coef. variación	47.5%

Figura 5.2: Boxplot de edad y tabla de medidas de dispersión

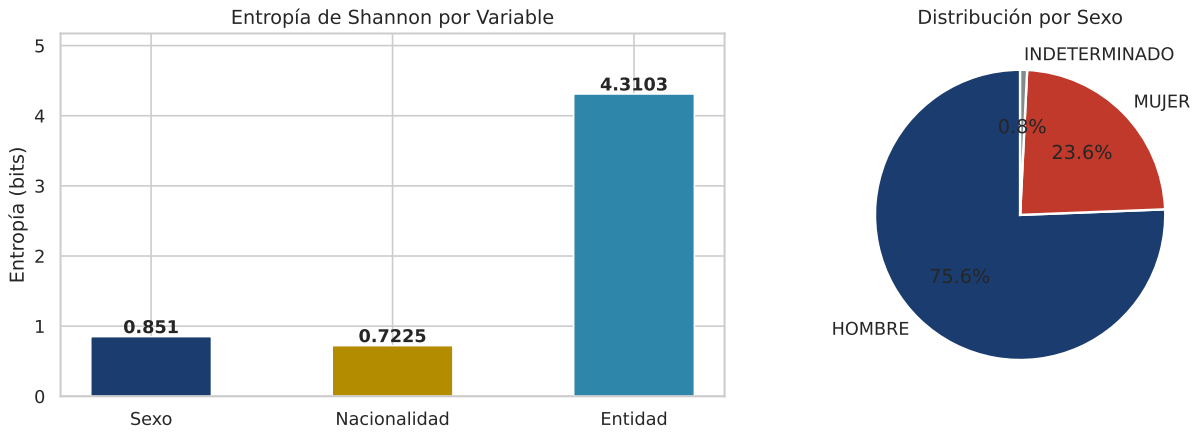

Figura 5.3: Entropía de Shannon por variable y distribución por sexo

5.3. Medidas de heterogeneidad

5.4. Medidas de concentración

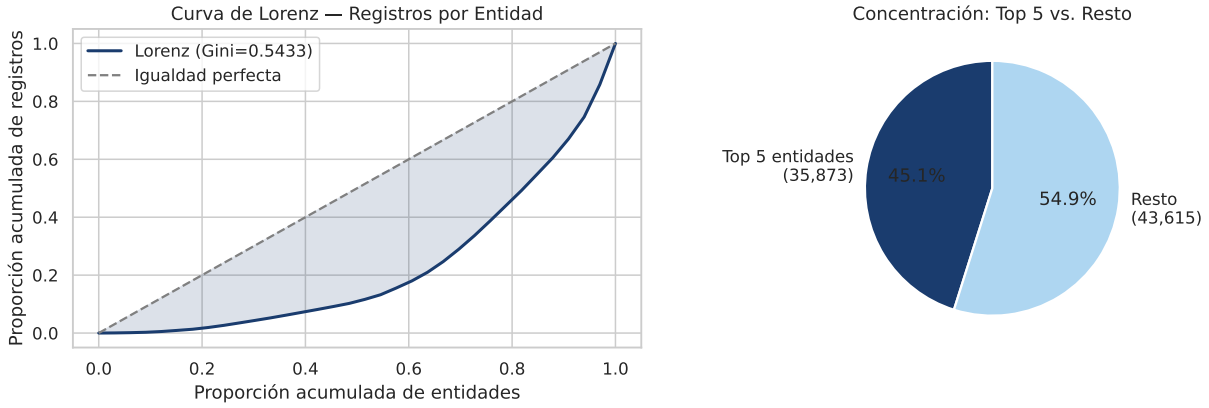

Figura 5.4: Curva de Lorenz y concentración en top 5 entidades

6 Correlación

6.1. Matriz de correlación

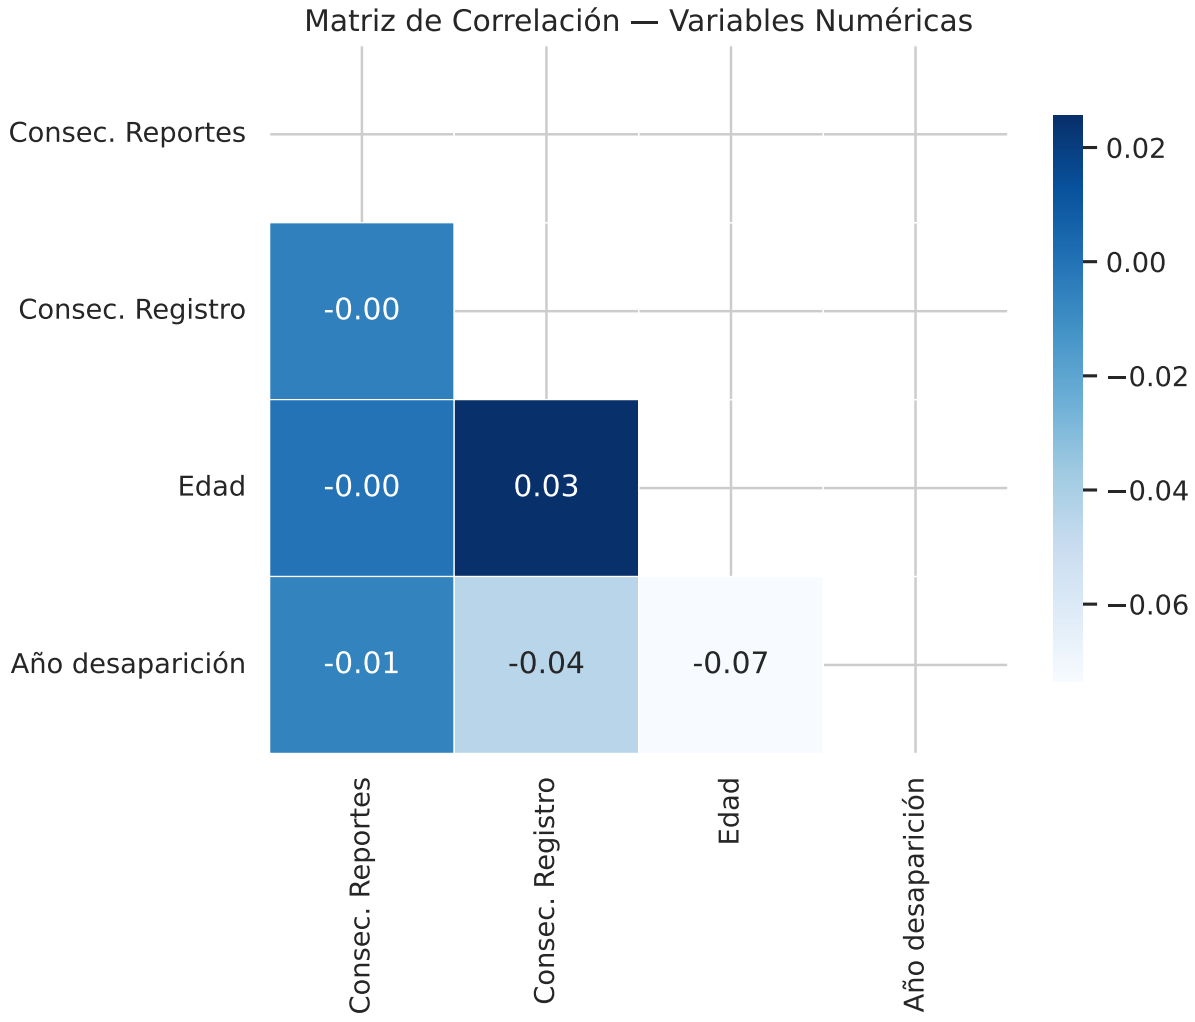

Figura 6.1: Matriz de correlación entre variables numéricas

6.2. Interpretación

Par de variables	r	Interpretación
Consec. Reportes – Consec. Registro	-0.00	Sin relación lineal
Consec. Reportes – Edad	-0.00	Sin relación lineal
Consec. Reportes – Año desap.	-0.01	Sin relación lineal
Consec. Registro – Edad	0.03	Correlación muy débil
Consec. Registro – Año desap.	-0.04	Correlación muy débil
Edad – Año desap.	**-0.07**	**Correlación más notable (aún muy débil)**

La matriz revela que **no existe ninguna correlación lineal relevante** entre las variables numéricas. La ausencia de correlaciones fuertes sugiere que cada variable aporta información independiente. Un análisis multivariado más profundo requeriría incorporar las variables categóricas mediante codificación adecuada.

7 Hallazgos

7.1. H1 — Tamaulipas concentra el mayor número

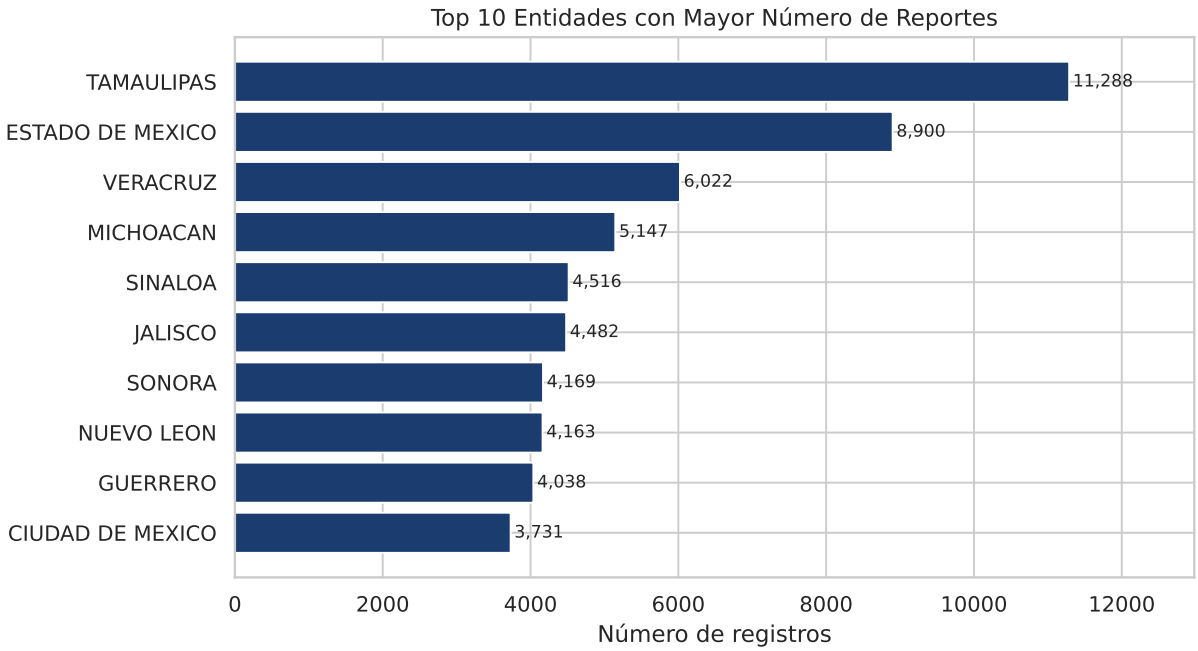

Figura 7.1: Top 10 entidades con mayor número de reportes de desaparición

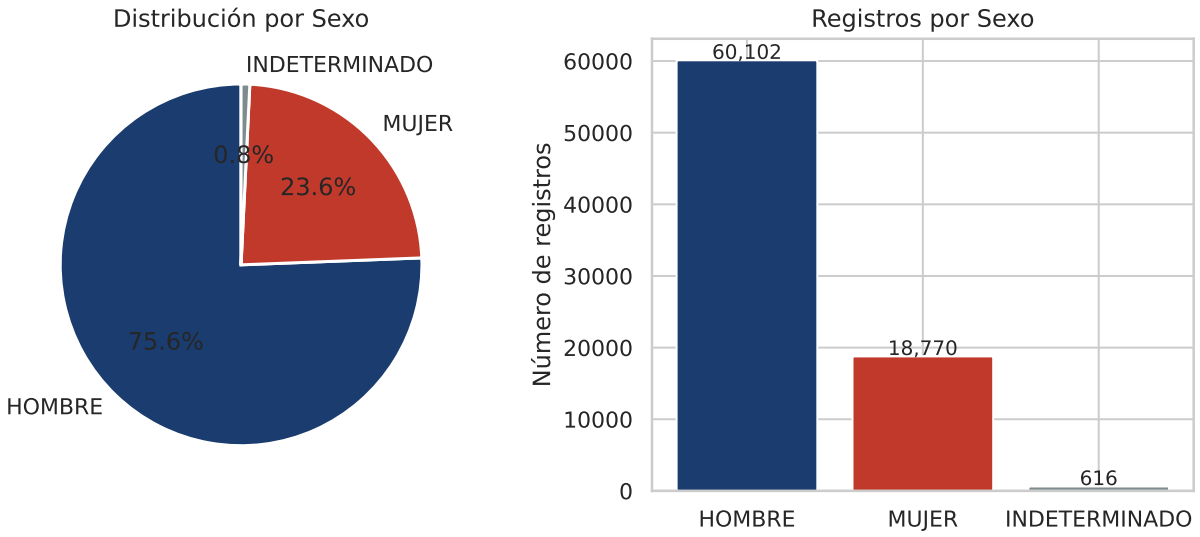

Figura 7.2: Distribución de registros por sexo

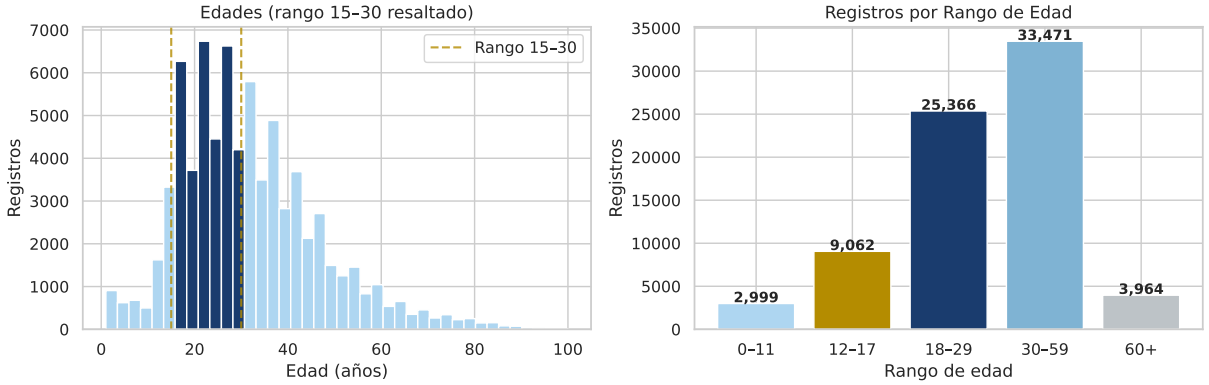

Figura 7.3: Distribución por edad con rango 15-30 resaltado y grupos etarios

Figura 7.4: Reportes de desaparición por año entre 2000 y 2023

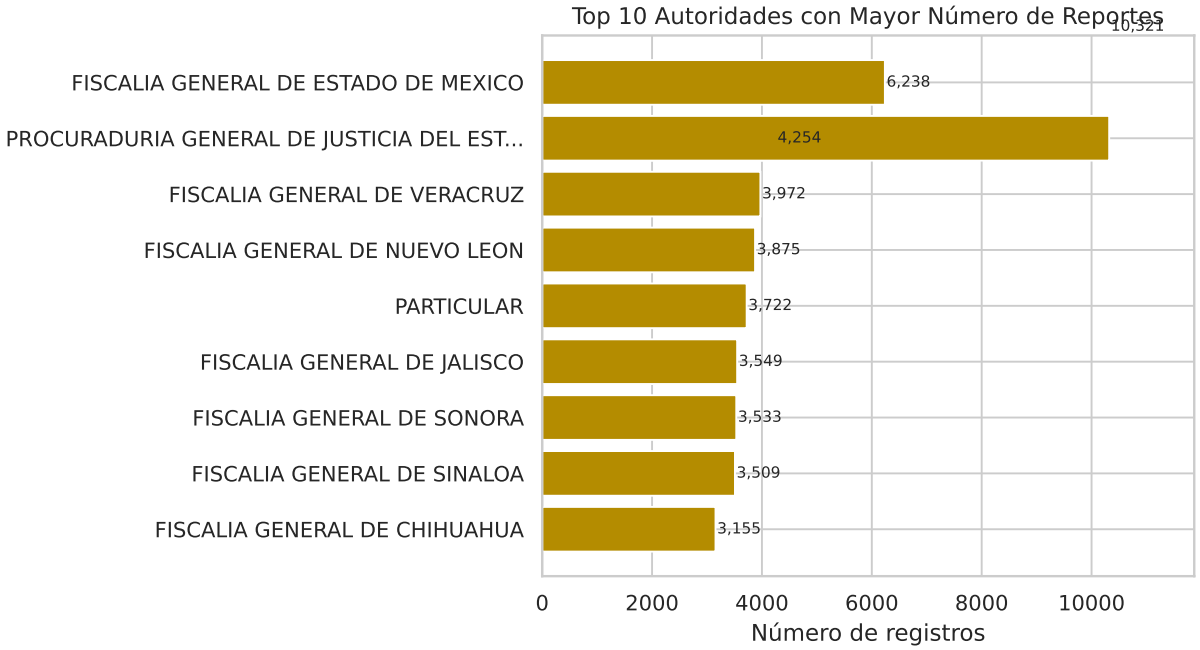

Figura 7.5: Top 10 autoridades con mayor número de reportes

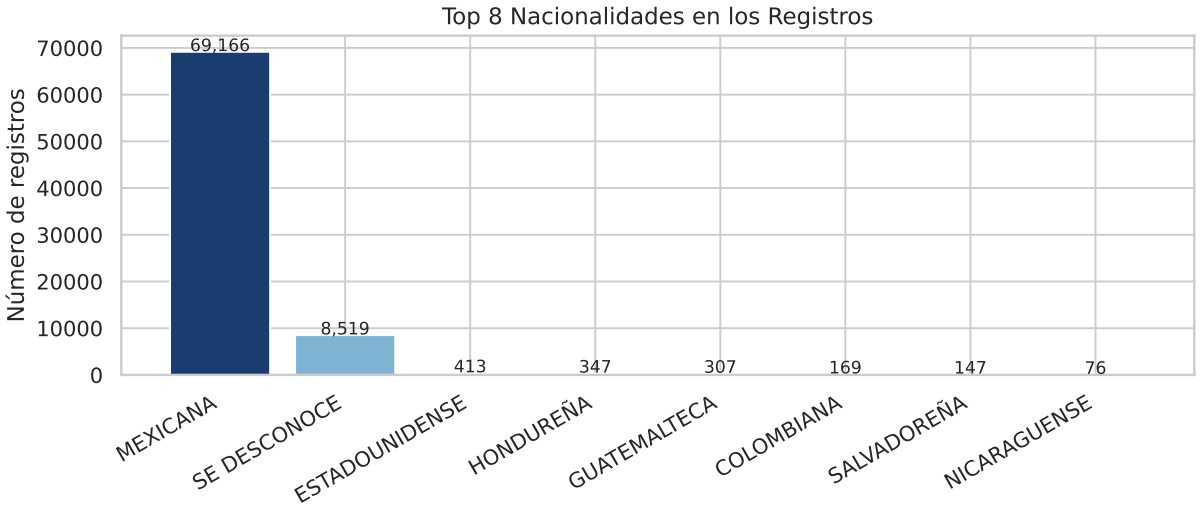

Figura 7.6: Top 8 nacionalidades en los registros

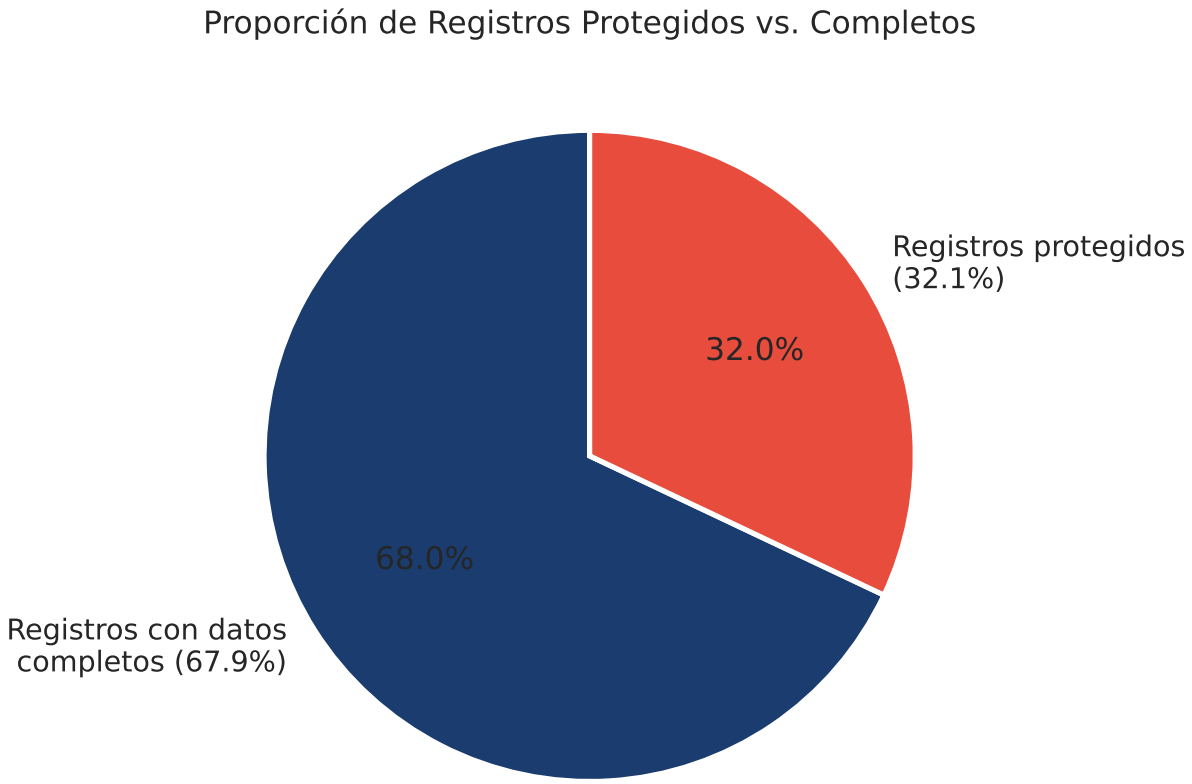

Figura 7.7: Proporción de registros protegidos vs. completos

7.2. H2 — Hombres: 3 de cada 4 registros

7.3. H3 — Jóvenes 15–30: grupo más vulnerable

7.4. H4 — Incremento sostenido desde 2006

7.5. H5 — Fiscalías estatales concentran reportes

7.6. H6 — 87.4 % de nacionalidad mexicana

7.7. H7 — 32.1 % de registros protegidos

7.8. H8 — Alta variabilidad en edad

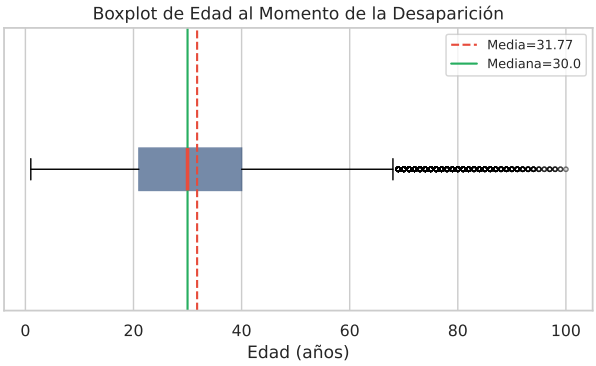

Resumen de Variabilidad — Edad

Medida estadística	Valor
Media	31.77
Mediana	30.0
Desv. estándar	15.09
Varianza	227.57
Rango	99
IQR	19.0
Coef. variación	47.5%

Figura 7.8: Boxplot de edad y resumen de variabilidad

8 Limitaciones

8.1. Calidad de los datos y sesgos

8.1.1. Calidad de los datos

La columna `Fecha de desaparición` concentra la mayor problemática: **56,085 valores nulos (70.56 %)** de tipo MNAR. Los análisis temporales se realizaron únicamente sobre los 23,403 registros con fecha válida, limitando la representatividad histórica.

La columna `Edad` presentaba 11 registros con valores > 100 años (máximo: 1,832) y 240 con valor $= 0$. Los 251 errores de captura fueron reemplazados por NaN.

8.1.2. Sesgos

- **Subregistro:** Una proporción significativa de desapariciones nunca llega a ser reportada (desconfianza institucional, miedo, desconocimiento de mecanismos de denuncia).
- **Sesgo por registros protegidos:** El 32.1 % de registros eliminados impide generalizar hallazgos demográficos al total de casos.
- **Heterogeneidad institucional:** Múltiples autoridades con distintos criterios introducen inconsistencias en categorías como entidad, autoridad y nacionalidad.
- **Subregistro de mujeres:** Las desapariciones de mujeres pueden estar subregistradas por patrones culturales, particularmente en casos de violencia de género o trata.

8.2. Variables faltantes y decisiones

8.2.1. Variables faltantes

El dataset público contiene únicamente **11 de las 450 variables** del RNPDNO completo. Variables ausentes clave:

- Municipio de desaparición
- Delito asociado al caso
- Estatus de localización (localizado / no localizado)
- Fecha de reporte
- Características físicas de la persona

8.2.2. Decisiones de limpieza documentadas

Decisión	Justificación
Eliminar 37,460 registros ELIMINADO	No contienen información utilizable (MNAR)
No imputar Fecha de desaparición	70.56 % faltantes MNAR — imputación introduciría sesgo grave
Reemplazar edades fuera de rango por NaN	Errores de captura sin forma de recuperar el dato real
Forward fill en Consecutivo Reportes	Propagar identificador a reportes adicionales
Corregir 4 variantes ortográficas en Nacionalidad	Homologar etiquetas equivalentes
Conservar 373 registros con fechas < 1990	Históricamente válidos (guerra sucia, 1970s)

9 Conclusión

9.1. Síntesis de hallazgos

El análisis exploratorio del dataset `RNPDNO-22-08-2023.csv` permitió identificar patrones claros en el fenómeno de las desapariciones en México a partir de **79,488 registros** con datos utilizables.

9.1.1. Dimensión geográfica

Las desapariciones no se distribuyen de forma uniforme. **Tamaulipas** concentra 11,288 casos, seguido por Estado de México (8,900) y Veracruz (6,022). El coeficiente de Gini de **0.54** confirma una concentración moderada-alta en pocas entidades, con implicaciones directas para la asignación de recursos de búsqueda.

9.1.2. Dimensión demográfica

Los **hombres jóvenes** son el grupo más afectado: 75.6 % de los registros son hombres y los jóvenes de 15–30 años representan el **45.4 % del total**. La moda de 16 años señala que la adolescencia tardía es el punto de mayor frecuencia.

La distribución presenta **sesgo positivo (a la derecha)** — Moda (16) $<$ Mediana (30) $<$ Media (31.77) — lo que indica que la **mediana e IQR** son medidas más representativas que la media y la desviación estándar para describir este conjunto de datos.

9.1.3. Dimensión temporal e institucional

Incremento sostenido desde **2006**, con pico en 2019 (2,462 casos). Las fiscalías estatales concentran la mayoría de reportes, subrayando la importancia de fortalecer capacidades institucionales a nivel local.

9.1.4. Perspectivas futuras

Este análisis sienta las bases para estudios más profundos con las 450 variables del registro completo, modelos de series de tiempo y análisis geoespaciales a nivel municipal. La disponibilidad de datos abiertos es un paso fundamental hacia la transparencia y rendición de cuentas.

Referencias

1. Comisión Nacional de Búsqueda de Personas. *RNPDNO — Versión Estadística*. SEGOB. https://versionpublicarnpdno.segob.gob.mx/Dashboard/ContextoGeneral
2. Google Developers. *Planificación de proyectos de AA*. https://developers.google.com/machine-learning/managing-ml-projects/planning?hl=es-419
3. José Antonio Rodríguez Serrano. *Acelerar el flujo de trabajo en Ciencia de Datos*. BBVA AI Factory, mayo 2025. https://www.bbvaaifactory.com/es/accelerating-data-science-workflows/
4. Martin Tingley et al. *Experimentation is a major focus of Data Science across Netflix*. Netflix Tech Blog, enero 2022. https://netflixtechblog.com/experimentation-is-a-major-focus-of-data-science-across-netflix-f67923f8e985
5. Observatorio sobre Desaparición e Impunidad en México, UNAM. https://odim.juridicas.unam.mx/
6. ¿A dónde van los desaparecidos? https://adondevanlosdesaparecidos.org/
7. Archivo General de la Nación. *El Ejército Mexicano durante la Guerra Sucia*. https://www.gob.mx/agn/articulos/el-ejercito-mexicano-durante-la-guerra-sucia