Universidad Nacional Autónoma de México

Facultad de Ciencias

Almacenes y Minería de Datos

Tarea 02

Profesora: Jessica Santizo Galicia

Ayudantes: Diego Antonio Villalba González, Ares Gael Castro Romero

Integrantes del Equipo:

Brenda Jiménez Ruiz

Irany Solano Marcial

Juan Luis Peña Mata

Fecha de entrega:

26 de marzo de 2026, a más tardar a las 23:59

1. Empresa y metodología de mineria de dato

Irany — BBVA

BBVA es una de las instituciones financieras más grandes de España y América Latina, con presencia activa en México. Su área de datos, conocida como BBVA Data & Analytics (D&A), ha documentado públicamente su enfoque metodológico para proyectos de minería de datos y ciencia de datos.

En BBVA D&A, los proyectos de ciencia de datos heredan características de CRISP-DM, una metodología originalmente diseñada para la minería de datos que define una tarea como un proceso con pasos generales que van desde la comprensión del problema hasta la preparación de datos, el modelado y la implementación. BBVA AI Factory Sin embargo, BBVA no aplica CRISP-DM de forma rígida. Con sus proyectos aumentando en número y diversidad, el equipo sintió la necesidad de abstraer y documentar un flujo de trabajo integral propio, no solo para su comprensión interna sino para encajar mejor sus proyectos en prácticas ágiles. BBVA AI Factory

Algunas de las herramientas que utilizan son:

- Herramientas para ayudar en búsqueda de datos (Data Discovery)
  - Amundsen: Motor de búsqueda de datos y metadatos para facilitar la búsqueda en bases de datos corporativas.
- Herramientas para la exploración de datos:
  - Tensorflow Data Validation: Explora bases de datos rápidamente utilizando el marco de trabajo de Tensorflow.
  - InspectDF: Una herramienta de R para resumir, inspeccionar y visualizar información dentro de un dataframe.
- Feature:
  - FeatureTOOLS: Descubrir atributos desde datos tabulados.
  - Ludwig: Herramientas para reutilizar representaciones (embeddings y capas de arquitectura) en Deep Learning para tipos complejos, como imágenes o textos.
  - BBVA Data & Analytics también ha experimentado con embeddings con entidades de domínios específicos con client2vec.

Entre las aplicaciones concretas de minería de datos en BBVA se encuentran la detección de perfiles de clientes fraudulentos, la estimación de la probabilidad de que clientes abandonen el banco, y la identificación de patrones de consumo para recomendación de productos financieros. BBVA [3]

2. Objetivo y Preguntas de Análisis

Brenda — Netflix

Netflix es una plataforma de entretenimiento por streaming con más de 300 millones de suscriptores en el mundo. Su enfoque de minería de datos se distingue por estar centrado en la experimentación continua como metodología principal.
Netflix tiene una cultura de experimentación y toma de decisiones basada en datos que permite probar nuevas ideas directamente en producción para obtener retroalimentación real de sus usuarios. Netflix Tech Blog A diferencia de metodologías estándar como CRISP-DM, Netflix desarrolló su propio proceso iterativo basado en el método científico. Los científicos de datos especializados en experimentación e inferencia causal participan en todo el ciclo de vida del proyecto: exploración de datos e ideación, diseño y ejecución de pruebas, análisis de resultados y síntesis de aprendizajes para informar decisiones.
El pilar técnico central de esta metodología es su plataforma de experimentación propia llamada ABlaze. Esta plataforma soporta más de 3,000 proyectos de inteligencia artificial y machine learning, ejecutando cientos de millones de trabajos de cómputo y gestionando decenas de petabytes de modelos y artefactos, con automatización de reportes y seguimiento de métricas en tiempo real. [4]

Juan — Google

Google es la empresa de tecnología más grande del mundo en términos de búsquedas y publicidad digital, y una de las pioneras en el uso de machine learning a escala masiva. Su metodología para proyectos de minería de datos y ML está documentada públicamente en sus guías para desarrolladores.[2]
Google reconoce que los proyectos de ML son fundamentalmente distintos a los proyectos de software tradicionales, ya que son no lineales y tienen grados variables de incertidumbre. En lugar de seguir un plan rígido, Google promueve una mentalidad experimental donde los equipos prueban múltiples enfoques en un proceso iterativo de prueba y error. Para gestionar esta complejidad, Google desarrolló su propio marco de buenas prácticas documentado en Rules of Machine Learning. Este marco organiza el desarrollo de ML en tres fases: una primera fase de construcción de infraestructura y pipeline, una segunda de lanzamiento e iteración agregando nuevas características y evaluando modelos, y una tercera de optimización avanzada cuando se alcanza un plateau de rendimiento.
A nivel de infraestructura, Google centraliza todos sus proyectos de datos en su plataforma Vertex AI, que ofrece una solución unificada para el ciclo de vida completo de ciencia de datos y machine learning, combinando motores analíticos como BigQuery con herramientas de MLOps[2].

2.1. Objetivo

El presente reporte tiene como objetivo analizar el datasets. `RNPDNO-22-08-2023.csv`, publicado por la **Comisión Nacional de Búsqueda de Personas (CNB)** de la Secretaría de Gobernación, con la finalidad de identificar patrones temporales, geográficos

y demográficos en los registros de personas desaparecidas y no localizadas en México. Los hallazgos están orientados a apoyar la toma de decisiones en materia de política pública y estrategias de búsqueda, presentados en un lenguaje accesible para audiencias no técnicas.

2.2. Preguntas de Análisis

1. ¿Cuáles son las entidades federativas con mayor número de reportes de desaparición?
2. ¿Qué distribución por sexo presentan los registros de personas desaparecidas?
3. ¿Qué grupos de edad son los más afectados por las desapariciones eportadas?
4. ¿Existe una tendencia temporal en el número de desapariciones reportadas entre 2000 y 2023?
5. ¿Qué autoridades concentran el mayor volumen de reportes y qué implica esto institucionalmente?
6. ¿Cuál es la composición de nacionalidades en los registros y qué refleja sobre la dimensión migratoria del fenómeno?
7. ¿Qué proporción del dataset original fue eliminada por contener registros protegidos y cómo afecta esto al análisis?
8. ¿Qué nivel de variabilidad presenta la edad de las personas desaparecidas y qué grupos etarios concentran el mayor riesgo?

2.3. Criterios de Éxito

El análisis se considerará exitoso si: (a) se identifican al menos 8 hallazgos sustentados con evidencia gráfica o tabular, (b) el dataset limpio presenta consistencia interna verificable y decisiones de limpieza documentadas, y (c) los resultados pueden ser comprendidos y utilizados por tomadores de decisiones sin formación técnica en ciencia de datos.

3. Descripción del Dataset

El dataset utilizado es el Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO). En su estado original contiene 116,945 filas y 11 columnas, donde cada fila representa un reporte de desaparición de una persona. Las columnas son: Consecutivo Reportes por Persona, Consecutivo Registro, Nombre, Primer Apellido, Segundo Apellido, Edad, Sexo, Nacionalidad, Fecha de desaparición, Entidad de desaparición y Autoridad que reportó. Una misma persona puede tener más de un reporte en el dataset, ya que distintas autoridades pueden reportar el mismo caso de forma independiente. La columna Consecutivo Reportes por Persona actúa como identificador de persona y solo aparece en

el primer reporte de cada una, quedando en blanco en los reportes adicionales. El dataset contiene 110,965 personas únicas distribuidas en 116,945 reportes.

3.1. Diccionario

Variable	**Descripción**	**Tipo de dato**	**Tipo estadístico**	**Interpretación de negocio**
Consecutivo Reportes por Persona	Número entero que identifica a cada persona desaparecida. Solo aparece en el primer reporte; en reportes adicionales queda en blanco.	Entero (int64)	Numérica discreta	Permite contar personas únicas y agrupar todos los reportes asociados a un mismo individuo.
Consecutivo Registro	Número entero que indica el orden del reporte dentro de los registros de una misma persona. Comienza en 1.	Entero (int64)	Numérica discreta	Permite identificar si un registro es el primero o un reporte adicional de la misma persona.
Nombre	Nombre(s) de pila de la persona desaparecida. Puede contener uno o varios nombres. Presenta 5 nulos (0.01 %).	Cadena (string)	Categórica nominal	Permite identificar individualmente a la persona reportada.
Primer Apellido	Primer apellido de la persona desaparecida. Presenta 26 nulos (0.03 %).	Cadena (string)	Categórica nominal	Complementa la identificación nominal de la persona.
Segundo Apellido	Segundo apellido de la persona desaparecida. Presenta 1,449 nulos (1.82 %) por ser un dato opcional.	Cadena (string)	Categórica nominal	Complementa la identificación nominal. Su ausencia no implica error de captura.

Continúa en la siguiente página

Variable	Descripción	Tipo de dato	Tipo estadístico	Interpretación de negocio
Edad	Edad en años cumplidos al momento de la desaparición. Rango válido tras limpieza: 1 a 100 años. Promedio: 31.8 años. Presenta 4,626 nulos (5.82 %).	Flotante (float64)	Numérica continua	Permite analizar los grupos de edad más vulnerables y construir perfiles de riesgo.
Sexo	Categoría que indica el sexo de la persona. Valores posibles: HOMBRE (75.6 %), MUJER (23.6 %), INDETERMINADO (0.8 %). Sin valores nulos.	Cadena (string)	Categórica nominal	Permite analizar patrones de desaparición por sexo e identificar grupos prioritarios de atención.
Nacionalidad	País de nacionalidad de la persona desaparecida. Valor más frecuente: MEXICANA (87.01 %). Presenta 2 nulos.	Cadena (string)	Categórica nominal	Permite identificar si las desapariciones afectan predominantemente a población nacional o migrante.
Fecha de desaparición	Fecha en que ocurrió la desaparición. Rango: 01/05/1968 al 20/08/2023. Presenta 56,085 nulos (70.56 %) de tipo MNAR. No se imputó por las razones descritas en la sección de limpieza.	Fecha (datetime64)	Numérica continua	Permite analizar la evolución temporal de las desapariciones. Debe usarse solo con los 23,403 registros que cuentan con fecha válida.

Continúa en la siguiente página

Variable	Descripción	Tipo de dato	Tipo estadístico	Interpretación de negocio
Entidad de desaparición	Estado de la República Mexicana donde ocurrió la desaparición. 32 valores posibles. Sin valores nulos. Entidad más frecuente: Tamaulipas (14.2 %).	Cadena (string)	Categórica nominal	Permite identificar las entidades con mayor incidencia y construir análisis geográficos de riesgo.
Autoridad que reportó	Institución que generó el reporte de desaparición. Variable con alta cardinalidad. Sin valores nulos.	Cadena (string)	Categórica nominal	Permite analizar qué instituciones concentran la mayor cantidad de reportes y evaluar la cobertura del sistema.

Cuadro 1: Diccionario de datos del RNPDNO

3.2. Limpieza de datos

La columna Consecutivo Reportes por Persona presentaba 5,980 valores nulos correspondientes a reportes adicionales de personas ya registradas. Se aplicó forward fill para propagar el identificador hacia los registros siguientes dentro de cada grupo, garantizando que todos los reportes quedaran correctamente asociados a su persona.

```
=== VALORES NULOS (NaN) ===
Consecutivo Reportes por Persona     5980
Consecutivo Registro                    0
Nombre                                  6
Primer Apellido                        39
Segundo Apellido                     2031
Edad                                 8275
Sexo                                    0
Nacionalidad                            2
Fecha de desaparición               59597
Entidad de desaparición                 0
Autoridad que reportó                   0
dtype: int64
```

Se identificaron 37,460 filas donde todos los campos de identidad contenían la etiqueta ELIMINADO seguida de un número por ejemplo, ELIMINADO 1, ELIMINADO 2. Estas etiquetas no representan datos faltantes aleatorios sino registros intencionalmente censurados en el sistema de origen, lo que corresponde a datos faltantes no al azar (MNAR).

La fecha falta porque genuinamente se desconoce en la realidad o porque el sistema de captura no la registró de forma sistemática. Por esta razón se decidió no aplicar ningún método de imputación, por tres motivos.
Primero, con el 70.56 % de valores faltantes cualquier método estaría esencialmente inventando la mayoría de la columna, lo que no reflejaría la realidad. Segundo, los métodos de imputación estándar como KNN o imputación múltiple asumen MAR, condición que no se cumple aquí porque ninguna otra variable del dataset permite estimar la fecha de desaparición cuando ese dato nunca existió. Tercero, imputar con media o mediana concentraría artificialmente miles de casos en fechas que quizás no corresponden a la realidad, introduciendo un sesgo grave en cualquier análisis temporal posterior y llevando potencialmente a conclusiones falsas sobre patrones de desaparición. Por tanto, esta columna se conserva con sus valores nulos y se utilizará únicamente en análisis donde se trabaje explícitamente con los 23,403 registros que sí cuentan con fecha. Dado que no es posible recuperar esta información, dichos valores fueron reemplazados por NaN y posteriormente las filas completamente censuradas fueron eliminadas del dataset. Tras este proceso el dataset quedó con 79,488 filas.

```
Filas antes: 116945
Filas eliminadas: 37457
Filas después: 79488
```

La columna Edad presentaba 11 registros con valores mayores a 100 años (con un máximo de 1,832) y 240 registros con valor igual a cero, todos correspondientes a errores de captura. Al ser una cantidad mínima (251 filas de 79,488) y no existir forma de conocer la edad real, estos valores fueron reemplazados por NaN. El rango de edad válido quedó entre 1 y 100 años con un promedio de 31.8 años.

```
=== RANGO DE FECHAS ===
Fecha más antigua: 1968-05-01 00:00:00
Fecha más reciente: 2023-08-20 00:00:00

=== RANGO DE EDAD ===
Edad mínima: 0.0
Edad máxima: 1832.0
Edad promedio: 31.7
```

La columna Fecha de desaparición fue convertida de texto al tipo datetime para permitir operaciones temporales. La columna Edad fue convertida a tipo numérico. Los valores que no pudieron convertirse correctamente fueron reemplazados automáticamente por NaN.

```
=== EDAD DESPUÉS DE LIMPIEZA ===
Edad mínima: 1.0
Edad máxima: 100.0
Edad promedio: 31.8
Nulos en Edad: 4626

=== RESUMEN FINAL DEL DATASET LIMPIO ===
Filas totales: 79488
Columnas: 11

Nulos por columna:
Consecutivo Reportes por Persona        0
```

3.3. Normalizaciń

Todas las columnas de tipo texto fueron convertidas a mayúsculas y se eliminaron espacios en blanco al inicio y al final de cada valor, para garantizar consistencia en las categorías.

```
=== TIPOS DE DATOS FINALES ===
Consecutivo Reportes por Persona            int64
Consecutivo Registro                        int64
Nombre                                        str
Primer Apellido                               str
Segundo Apellido                              str
Edad                                        float64
Sexo                                          str
Nacionalidad                                  str
Fecha de desaparición               datetime64[us]
Entidad de desaparición                       str
Autoridad que reportó                         str
dtype: object
```

Se identificaron cuatro etiquetas con errores ortográficos que representaban la misma nacionalidad que otras ya existentes en el dataset. Se realizaron las siguientes correcciones: HONDUREÑAO fue corregida a HONDUREÑA, unificando 326 registros con los 21 ya existentes para un total de 347. SALVADORENA fue corregida a SALVADOREÑA. BRASILENA fue corregida a BRASILEÑA. BELICENA fue corregida a BELICEÑA.

```
=== NACIONALIDAD DESPUÉS DE HOMOLOGAR ===
Nacionalidad
MEXICANA          69166
SE DESCONOCE       8519
ESTADOUNIDENSE      413
HONDUREÑA           347
GUATEMALTECA        307
COLOMBIANA          169
SALVADOREÑA         147
NICARAGUENSE         76
VENEZOLANA           50
CUBANA               42
ECUATORIANA          41
PERUANA              34
CANADIENSE           22
HINDU                18
BELICEÑA             14
BRASILEÑA            11
ARGENTINA            10
RUSA                  9
DOMINICANA            8
ITALIANA              7
Name: count, dtype: int64
```

Se verificó que no existieran fechas futuras posteriores a 2024, confirmando que ningún registro las presentaba. Se identificaron 373 registros con fechas anteriores a 1990, los cuales fueron conservados por considerarse históricamente válidos, ya que corresponden a desapariciones ocurridas durante la guerra sucia en México en la década de 1970. La concentración de fechas en el primer día de cada mes sugiere que fueron registros ingresados tardíamente con precisión de fecha limitada, lo cual es una característica del dato y no un error.[1]

```
=== FECHAS ANTERIORES A 1990 ===
Registros con fecha antes de 1990: 373
Fecha de desaparición
1974-01-01    41
1974-10-01    33
1974-08-01    17
1976-01-01    16
1974-09-01    10
1974-10-10    10
1975-01-01     9
1974-09-20     7
1978-01-05     6
1974-08-23     6
Name: count, dtype: int64

=== FECHAS FUTURAS ===
Registros con fecha después de 2024: 0
```

Nuestro dataset limpio queda de la siguiente forma:

Característica	Valor
Número de filas	79,488
Número de columnas	11
Periodo cubierto	01/05/1968 al 20/08/2023
Personas únicas	77,259
Unidad de análisis	Cada fila representa un reporte de desaparición

Valores nulos restantes: Los nulos que permanecen en el dataset limpio los justificamos de la siguiente forma. Segundo Apellido tiene 1,449 nulos (1.82 %) porque no todas las personas tienen segundo apellido. Edad tiene 4,626 nulos (5.82 %) correspondientes a casos donde el dato simplemente no fue registrado en el reporte. Fecha de desaparición tiene 56,085 nulos (70.56 %) que son MNAR, es decir, el sistema de captura no registró este dato de forma sistemática y su ausencia no es aleatoria sino estructural. El resto de columnas presentan nulos menores al 0.03 %, considerados despreciables.

4. Hallazgos Principales

4.1. Aplicación de CRISP-DM al Dataset RNPDNO

La metodología CRISP-DM se aplicó de forma integral a lo largo de este reporte. La siguiente tabla resume cómo cada fase se corresponde con el contenido desarrollado.

Cuadro 2: Correspondencia entre las fases de CRISP-DM y el contenido del reporte

Fase	Actividades	Sección
1. Business Understanding	Objetivo, preguntas y criterios de éxito	Sección 2
2. Data Understanding	Descripción, diccionario y EDA	Secciones 2, 2.1, 3.2, 3.4
3. Data Preparation	Limpieza, conversión y normalización	Secciones 2.2, 2.3
4. Modelling	Técnicas sugeridas (clustering, series de tiempo)	—
5. Evaluation	Sesgos, limitaciones y calidad de datos	Sección 5
6. Deployment	Reporte PDF, dashboard Quarto, CSV limpio	Sección 6

4.1.1. Fase 4: Modelling — Técnicas sugeridas

Aunque en este proyecto no se entrenaron modelos predictivos, se identifican las técnicas más adecuadas para un análisis posterior:

- **Clustering (HDBSCAN o K-Means):** para identificar grupos de entidades con patrones similares de desaparición por edad, sexo y frecuencia temporal.
- **Series de tiempo (Prophet o ARIMA):** para modelar la tendencia de reportes anuales y proyectar el comportamiento futuro.
- **Clasificación supervisada:** si se dispusiera de la variable *localizado/no localizado*, podría predecirse el probable resultado de una búsqueda en función del perfil demográfico y geográfico del caso.

4.2. Cálculo de medidas con visualizaciones e interpretación

4.2.1. Medidas de Localización

Las medidas de localización permiten identificar los valores centrales de la distribución de edades de las personas registradas como desaparecidas.

Cuadro 3: Medidas de localización — variable *Edad*

Medida	**Valor**
Media	31.77 años
Mediana	30.00 años
Moda	16.00 años
Cuartil 1 (Q1)	21.00 años
Cuartil 3 (Q3)	40.00 años

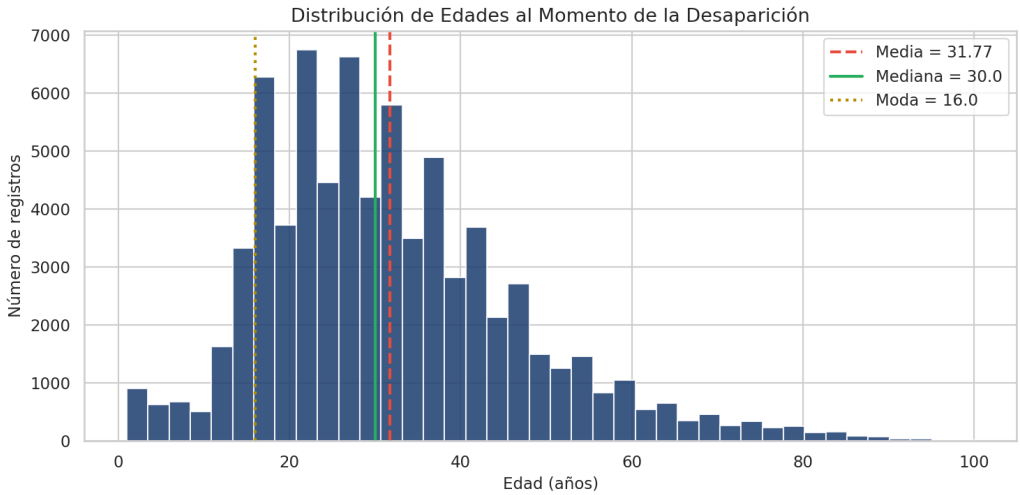

Figura 1: Distribución de edades al momento de la desaparición con indicadores de tendencia central.

La distribución de edades presenta una ligera asimetría positiva, evidenciada por la diferencia entre la media (31.77 años) y la mediana (30 años). La moda de 16 años resulta particularmente relevante desde una perspectiva social, ya que indica que los adolescentes constituyen el grupo etario con mayor frecuencia de desaparición en el dataset. El 50 % central de los registros se concentra entre los 21 y los 40 años (IQR = 19), lo que señala que la población en edad joven adulta es la más afectada.

Dado que Moda = 16 < Mediana = 30 < Media = 31,77, la distribución presenta un **sesgo positivo o a la derecha**, lo que indica que existe una cola extendida hacia edades mayores que jala la media por encima de la mediana. En presencia de este sesgo y considerando la existencia de valores atípicos en edades muy avanzadas (confirmados por el boxplot), la **mediana (30 años)** y el **rango intercuartílico (IQR = 19 años)** resultan medidas más representativas del comportamiento central y la dispersión típica de los datos que la media y la desviación estándar, ya que estas últimas son sensibles a los valores extremos.

4.2.2. Medidas de Variabilidad

Las medidas de variabilidad cuantifican la dispersión de los datos alrededor de los valores centrales de la variable *Edad*.

Cuadro 4: Medidas de variabilidad — variable *Edad*

Medida	**Valor**
Desviación estándar	15.09 años
Varianza	227.57 años^2
Rango	99 años
Rango intercuartílico (IQR)	19.00 años
Coeficiente de variación (CV)	47.50 %

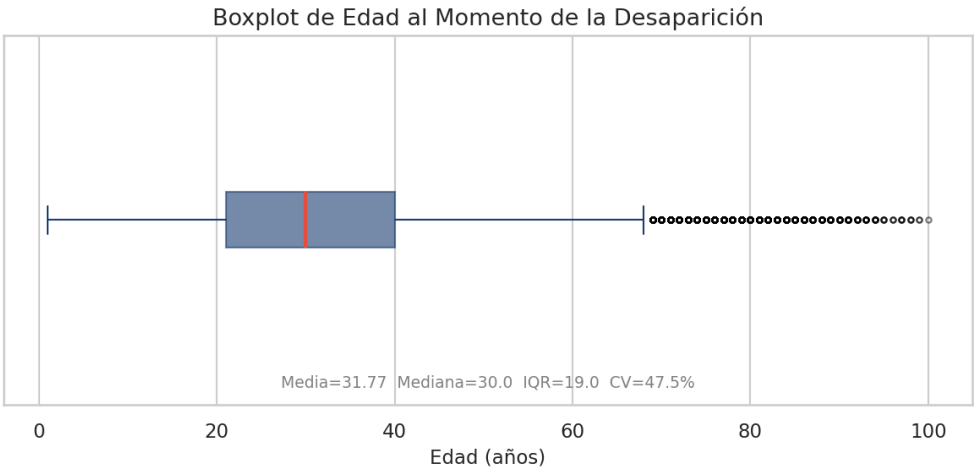

Figura 2: Boxplot de la edad al momento de la desaparición.

La desviación estándar de 15.09 años, junto con un coeficiente de variación del 47.5 %, indica una dispersión moderada-alta respecto a la media. El rango total de 99 años refleja que el dataset abarca desde recién nacidos hasta personas de avanzada edad. Sin embargo, el rango intercuartílico de 19 años es relativamente compacto, lo que sugiere que la mayor parte de las desapariciones se concentran en una franja etaria acotada. El boxplot confirma la presencia de valores atípicos en los extremos, particularmente en edades muy avanzadas.

Dado el sesgo a la derecha identificado en la distribución, se recomienda interpretar la variabilidad principalmente a través del **IQR = 19 años** (robusto a valores atípicos) en lugar del rango total de 99 años, el cual está fuertemente influenciado por los valores extremos en edades avanzadas.

4.2.3. Medidas de Heterogeneidad

La entropía de Shannon mide el grado de diversidad dentro de las variables categóricas. Un valor más alto indica mayor heterogeneidad en la distribución de categorías.

Cuadro 5: Entropía de Shannon por variable categórica

Variable	Entropía (bits)	Interpretación
Sexo	0.851	Baja heterogeneidad
Nacionalidad	0.722	Baja heterogeneidad
Entidad de desaparición	4.310	Alta heterogeneidad

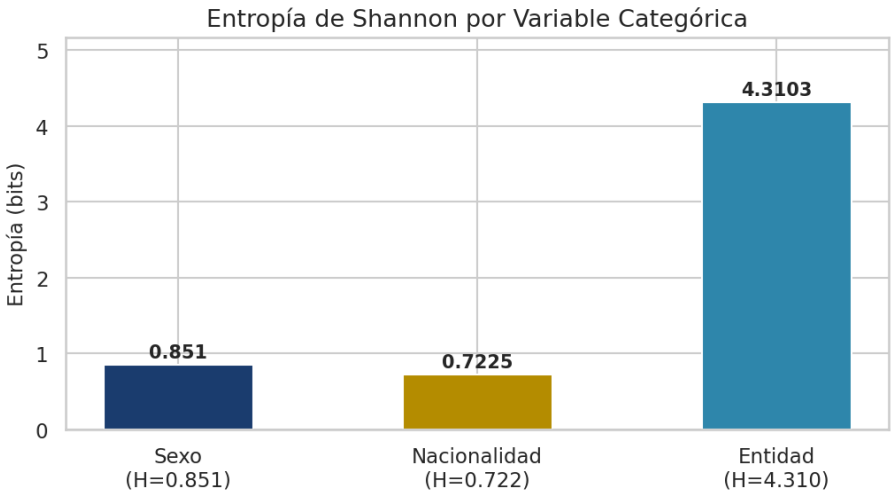

Figura 3: Entropía de Shannon para las variables categóricas del dataset.

La variable *Entidad de desaparición* presenta la mayor heterogeneidad (H = 4.31 bits), lo que refleja que los reportes se distribuyen de forma diversa a lo largo de las 32 entidades federativas, aunque con concentraciones notables en ciertos estados. Por el contrario, la variable *Sexo* muestra baja heterogeneidad (H = 0.851 bits), indicando que la distribución está dominada por una o dos categorías. La *Nacionalidad* presenta la menor diversidad (H = 0.722 bits), lo cual es esperable dado que la gran mayoría de los registros corresponden a personas de nacionalidad mexicana.

4.2.4. Medidas de Concentración

La curva de Lorenz y el coeficiente de Gini permiten evaluar qué tan concentrados están los registros de desaparición entre las distintas entidades federativas.

Cuadro 6: Coeficiente de Gini — concentración de registros por entidad

Medida	Valor
Coeficiente de Gini	0.5433

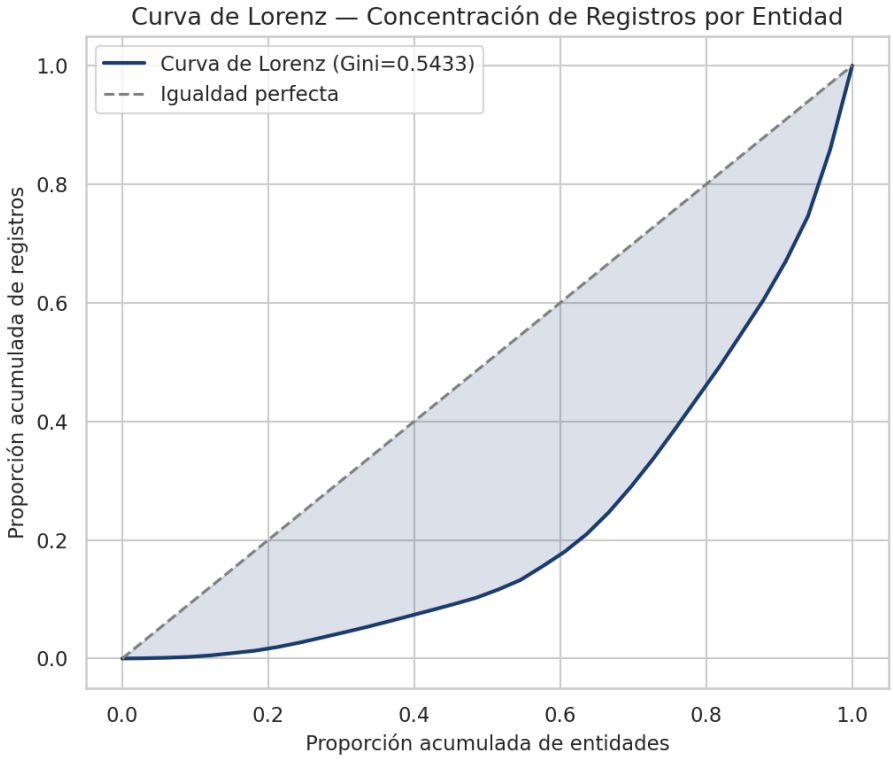

Figura 4: Curva de Lorenz para la concentración de registros por entidad federativa.

Un coeficiente de Gini de 0.54 indica una concentración moderada-alta de los registros de desaparición en pocas entidades federativas. La curva de Lorenz se aleja considerablemente de la diagonal de igualdad perfecta, confirmando que la distribución no es uniforme entre los estados. Esto implica que ciertas entidades acumulan una proporción desproporcionada de los casos, lo que tiene implicaciones directas para la asignación de recursos y el diseño de políticas públicas de atención a personas desaparecidas.

4.3. Hallazgos Principales

4.3.1. Hallazgo 1: Tamaulipas concentra el mayor número de desapariciones

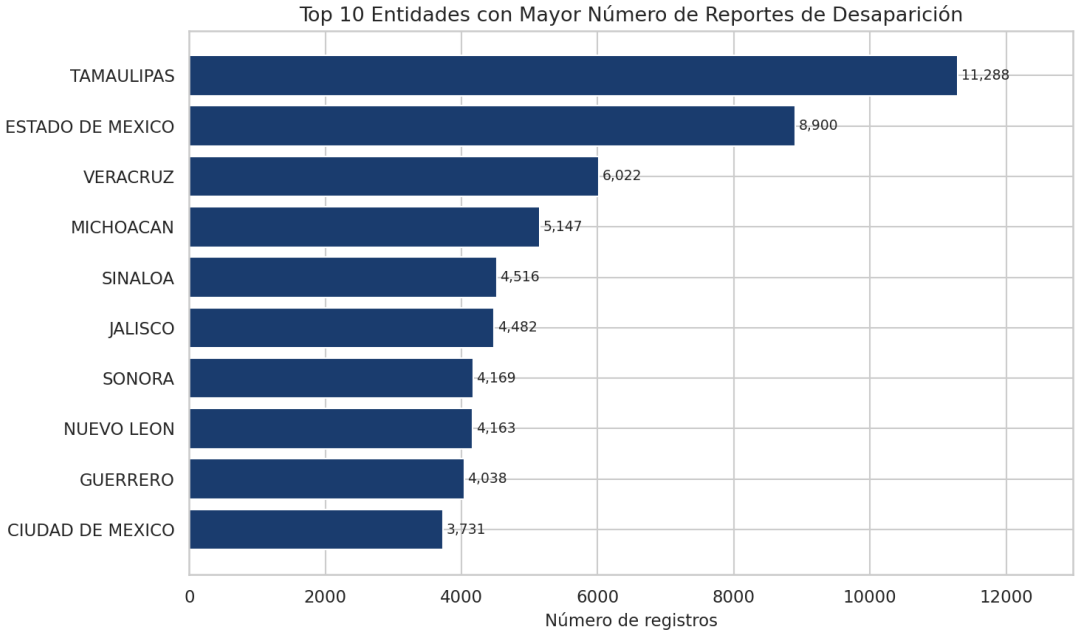

Figura 5: Top 10 entidades federativas con mayor número de reportes de desaparición.

Cuadro 7: Top 10 entidades con mayor número de registros de desaparición

Posición	Entidad	Registros
1	Tamaulipas	11,288
2	Estado de México	8,900
3	Veracruz	6,022
4	Michoacán	5,147
5	Sinaloa	4,516
6	Jalisco	4,482
7	Sonora	4,169
8	Nuevo León	4,163
9	Guerrero	4,038
10	Ciudad de México	3,731

Tamaulipas encabeza la lista con 11,288 registros, más del doble que el tercer lugar (Veracruz, 6,022), lo que refleja la grave situación de seguridad que ha atravesado esa entidad durante los últimos años. El Estado de México ocupa el segundo lugar con 8,900 casos, concentración que en parte puede explicarse por su alta densidad poblacional. En

conjunto, estas 10 entidades agrupan la mayoría de los registros del dataset, lo que evidencia una distribución geográfica marcadamente desigual del fenómeno de desaparición en México.

4.3.2. Hallazgo 2: Los hombres representan tres cuartas partes de los registros

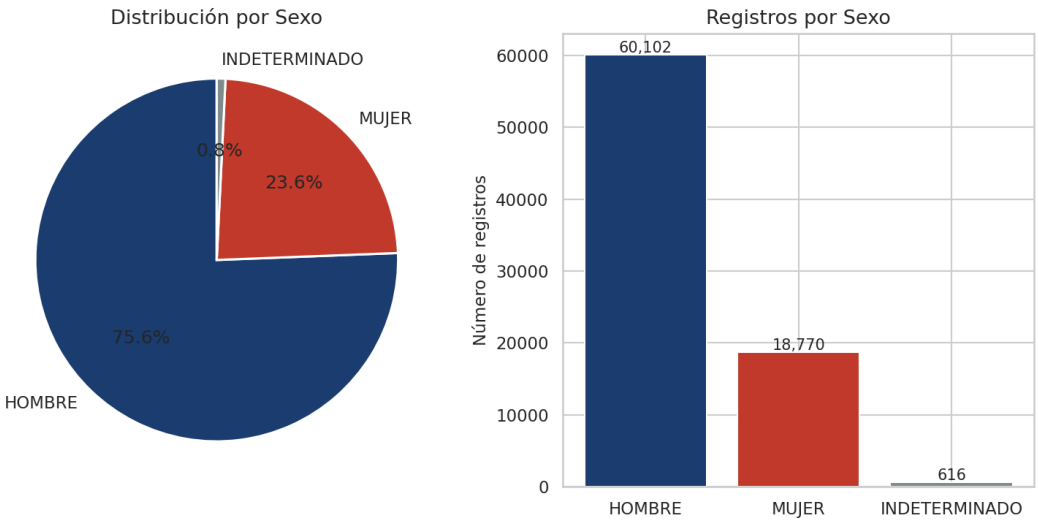

Figura 6: Distribución de registros de desaparición por sexo.

Cuadro 8: Registros de desaparición por sexo

Sexo	**Registros**	**Porcentaje**
Hombre	60,102	75.6 %
Mujer	18,770	23.6 %
Indeterminado	616	0.8 %
Total	**79,488**	**100 %**

El 75.6 % de los registros corresponde a hombres (60,102 casos), mientras que las mujeres representan el 23.6 % (18,770 casos). Esta brecha significativa sugiere que los hombres enfrentan un riesgo considerablemente mayor de desaparición, posiblemente asociado a dinámicas de violencia organizada, reclutamiento forzado o actividades laborales en contextos de riesgo. No obstante, es importante considerar que las desapariciones de mujeres pueden estar subregistradas debido a patrones culturales que desincentivan la denuncia, particularmente en casos de violencia de género o trata de personas.

4.3.3. Hallazgo 3: Los jóvenes de 15 a 30 años son el grupo más vulnerable

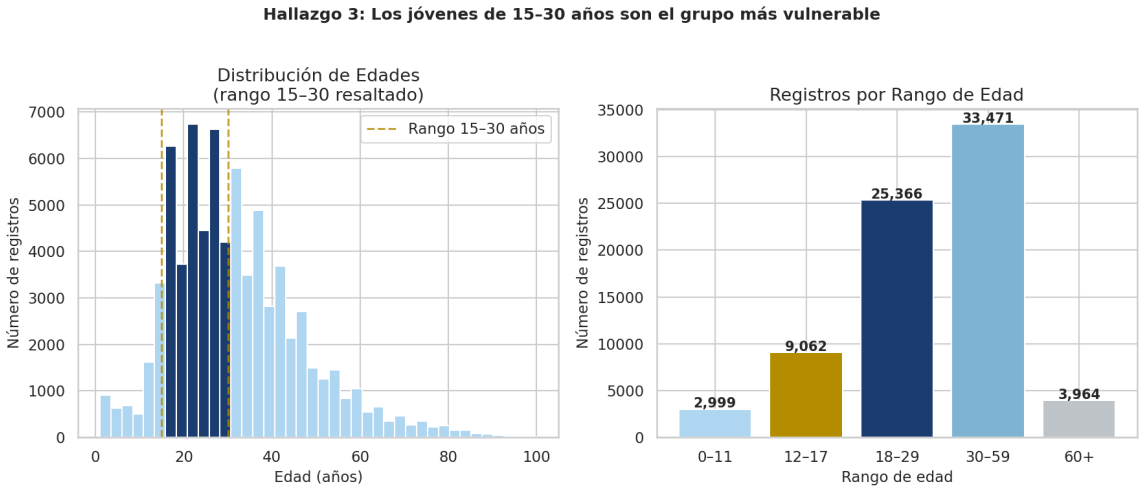

Figura 7: Distribución de edades con el rango 15–30 años resaltado (izquierda) y conteo por grupo etario (derecha).

Cuadro 9: Registros de desaparición por grupo etario

Grupo etario	Registros	Porcentaje
0–11 años	2,999	4.0 %
12–17 años	9,062	12.0 %
18–29 años	25,366	33.6 %
30–59 años	33,471	44.3 %
60+ años	3,964	5.2 %
Jóvenes 15–30	**33,963**	**45.4 %**

Los jóvenes de entre 15 y 30 años representan el 45.4 % del total de registros, consolidándose como el grupo etario más afectado. El rango de 18 a 29 años concentra el 33.6 % de los casos de forma individual, y la moda de 16 años señala que la adolescencia tardía es el punto de mayor frecuencia de desaparición. Esta concentración en edades jóvenes puede estar relacionada con la vulnerabilidad al reclutamiento forzado por grupos del crimen organizado, así como con situaciones de migración irregular. Estos hallazgos apuntan a la necesidad de políticas de prevención focalizadas en adolescentes y jóvenes adultos.

4.3.4. Hallazgo 4: Los reportes de desaparición se incrementaron a partir de 2006

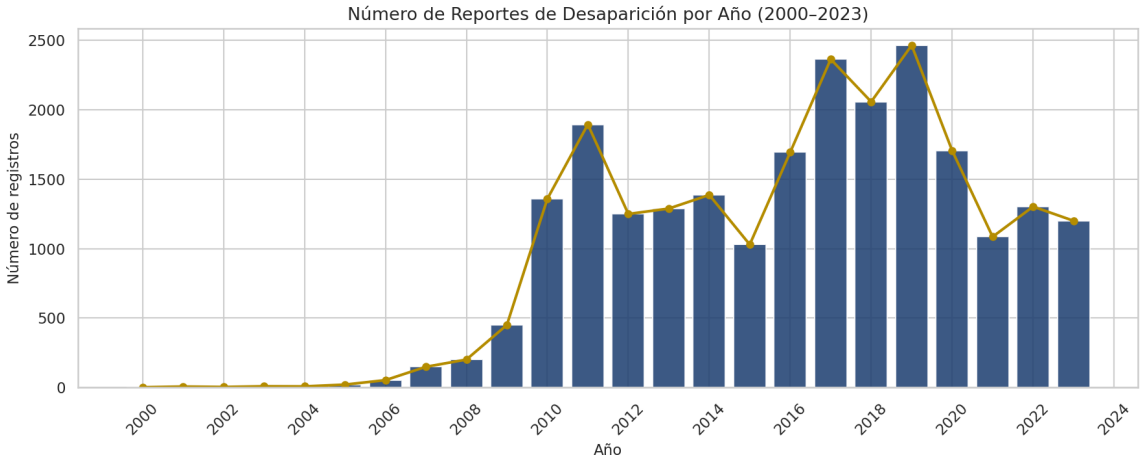

Figura 8: Número de reportes de desaparición por año (2000–2023).

La tendencia temporal muestra un crecimiento sostenido en el número de reportes de desaparición a partir de 2006, año que coincide con el inicio de la estrategia federal de seguridad conocida como "guerra contra el narcotráfico". El pico más alto se registró en 2019 con 2,462 casos. Cabe señalar que los datos de años recientes pueden estar subregistrados debido al tiempo que transcurre entre la desaparición, la denuncia formal y la incorporación al registro oficial. La tendencia general refleja tanto un aumento real del fenómeno como una mejora progresiva en los mecanismos de denuncia y registro institucional a lo largo del periodo analizado.

4.3.5. Hallazgo 5: Las procuradurías y fiscalías estatales concentran la mayoría de los reportes

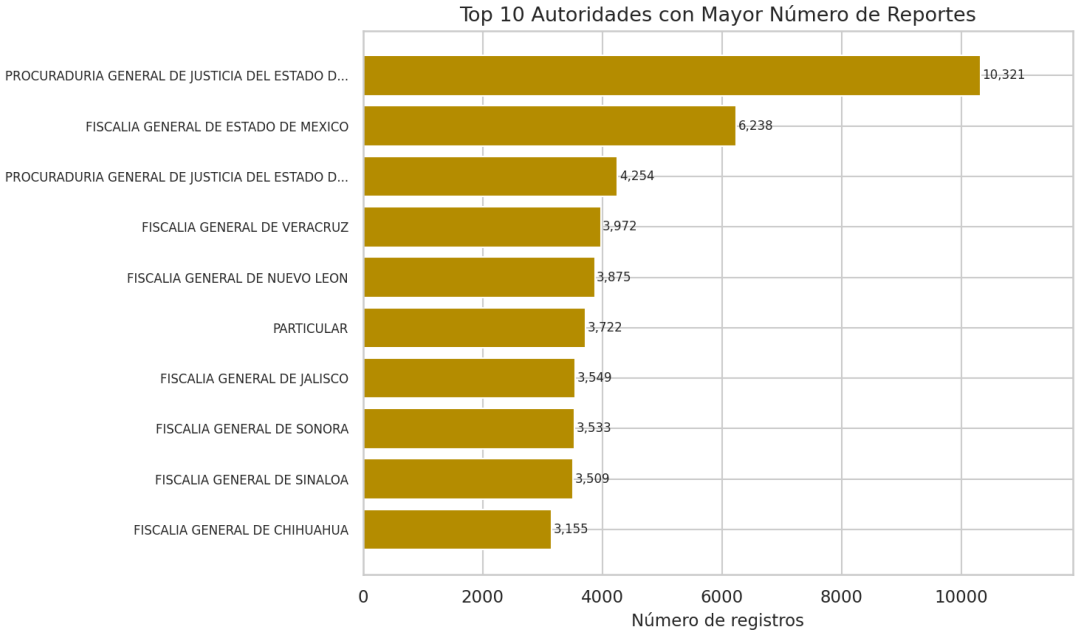

Figura 9: Top 10 autoridades con mayor número de reportes registrados.

Cuadro 10: Top 5 autoridades con mayor número de reportes

Autoridad	Registros
Procuraduría General de Justicia del Estado de Tamaulipas	10,321
Fiscalía General del Estado de México	6,238
Procuraduría General de Justicia del Estado de Michoacán	4,254
Fiscalía General de Veracruz	3,972
Fiscalía General de Nuevo León	3,875

Las autoridades estatales —procuradurías y fiscalías— son las principales receptoras de los reportes de desaparición, lo que refleja que la atención a este fenómeno recae primordialmente en el ámbito local. La Procuraduría de Tamaulipas encabeza la lista con 10,321 registros, consistente con el primer lugar que ocupa esa entidad en el hallazgo anterior. La concentración en instancias estatales subraya la importancia de fortalecer las capacidades institucionales a nivel local para la investigación, búsqueda y atención a familiares de personas desaparecidas.

4.3.6. Hallazgo 6: La gran mayoría de las personas desaparecidas son de nacionalidad mexicana

Figura 10: Top 8 nacionalidades presentes en los registros de desaparición.

Cuadro 11: Distribución de registros por nacionalidad (top 8)

Nacionalidad	Registros	Porcentaje
Mexicana	69,166	87.4 %
Se desconoce	8,519	10.8 %
Estadounidense	413	0.5 %
Hondureña	347	0.4 %
Guatemalteca	307	0.4 %
Colombiana	169	0.2 %
Salvadoreña	147	0.2 %
Nicaragüense	76	0.1 %

El 87.4 % de los registros corresponde a personas de nacionalidad mexicana (69,166 casos), lo que era esperable dado que se trata de un registro nacional. Sin embargo, destaca la presencia de personas de nacionalidad hondureña (347), guatemalteca (307) y salvadoreña (147), que en conjunto representan el 1 % del total y evidencian la dimensión migratoria del fenómeno. Adicionalmente, el 10.8 % de los registros (8,519 casos) no cuenta con nacionalidad identificada, lo que constituye una limitación relevante para el análisis y señala áreas de mejora en la captura de datos.

4.3.7. Hallazgo 7: El 32.1 % de los registros originales fueron eliminados por estar protegidos

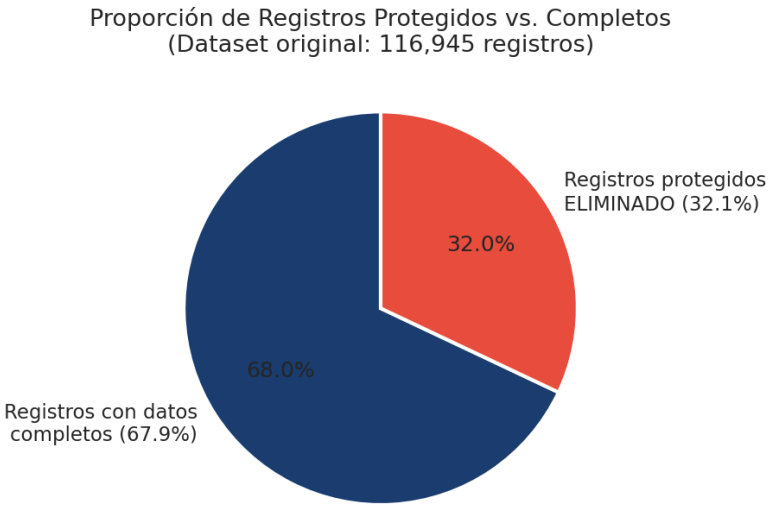

Figura 11: Proporción de registros protegidos eliminados frente a registros con datos completos en el dataset original.

Cuadro 12: Registros protegidos vs. completos en el dataset original

Tipo de registro	**Cantidad**	**Porcentaje**
Con datos completos	79,485	67.9 %
Protegidos (eliminados)	37,460	32.1 %
Total original	**116,945**	**100 %**

El dataset original del RNPDNO contenía 116,945 registros, de los cuales 37,460 (32.1 %) fueron clasificados como protegidos y debieron ser eliminados durante el proceso de limpieza, ya que no contenían información utilizable para el análisis. Este porcentaje representa una pérdida significativa de información que podría sesgar los resultados, especialmente si los registros protegidos corresponden de manera desproporcionada a ciertos estados, grupos de edad o periodos temporales. Esta limitación debe considerarse al interpretar cualquier hallazgo derivado del dataset limpio.

4.3.8. Hallazgo 8: Alta variabilidad en la edad de las personas desaparecidas

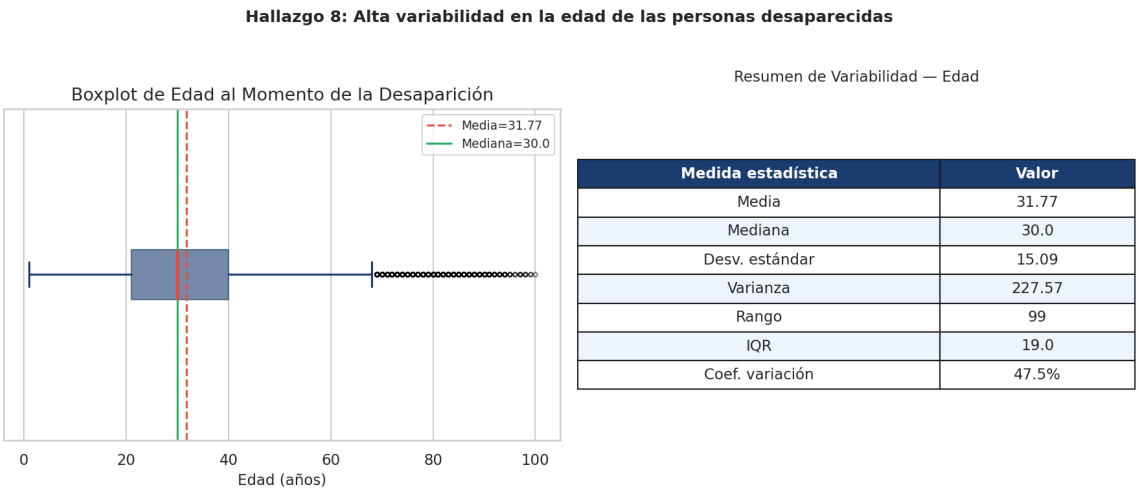

Medida estadística	Valor
Media	31.77
Mediana	30.0
Desv. estándar	15.09
Varianza	227.57
Rango	99
IQR	19.0
Coef. variación	47.5%

Figura 12: Boxplot de la edad al momento de la desaparición (izquierda) y resumen de medidas de variabilidad (derecha).

Cuadro 13: Medidas de variabilidad — variable *Edad*

Medida estadística	**Valor**
Media	31.77 años
Mediana	30.00 años
Desviación estándar	15.09 años
Varianza	227.57 años^2
Rango	99 años
Rango intercuartílico (IQR)	19.00 años
Coeficiente de variación (CV)	47.50 %

La edad de las personas desaparecidas presenta una dispersión moderada-alta, con una desviación estándar de 15.09 años y un coeficiente de variación del 47.5 %, lo que indica que la variable es heterogénea en relación con su media. El rango total de 99 años confirma que la desaparición afecta a todos los grupos etarios, desde recién nacidos hasta personas de avanzada edad. No obstante, el rango intercuartílico de 19 años (Q1 = 21, Q3 = 40) muestra que el núcleo central de los casos se concentra en la población joven y adulta temprana. El boxplot evidencia la presencia de valores atípicos en edades avanzadas que amplían la varianza pero no desplazan significativamente la mediana, lo que refuerza que la distribución está sesgada hacia edades jóvenes.

4.4. Correlación entre Variables Numéricas

Se calculó la matriz de correlación de Pearson para las cuatro variables numéricas disponibles: *Consecutivo Reportes por Persona*, *Consecutivo Registro*, *Edad* y *Año de desaparición*.

Cuadro 14: Matriz de correlación de Pearson — variables numéricas

	Consec. Reportes	**Consec. Registro**	**Edad**	**Año desap.**
Consec. Reportes	1.00	-0.00	-0.00	-0.01
Consec. Registro	-0.00	1.00	0.03	-0.04
Edad	-0.00	0.03	1.00	-0.07
Año desap.	-0.01	-0.04	-0.07	1.00

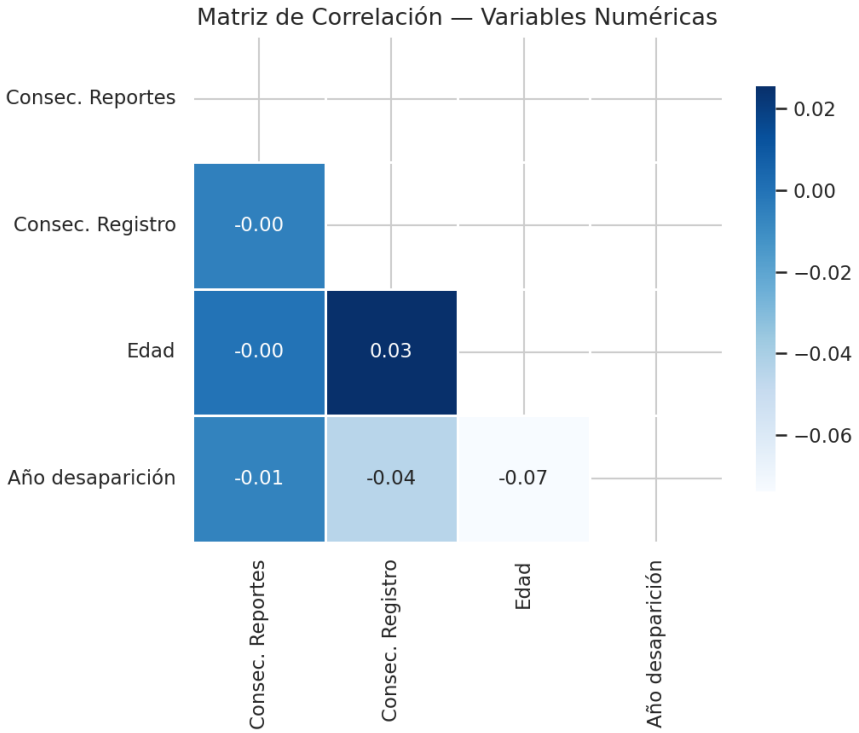

Figura 13: Mapa de calor de la matriz de correlación entre variables numéricas.

La matriz de correlación revela que no existe ninguna correlación lineal relevante entre las variables numéricas del dataset. La asociación más notable es entre *Año de desaparición* y *Edad* ($r = -0{,}07$), la cual es prácticamente nula. Esto es esperable, ya que los campos consecutivos son identificadores administrativos sin relación intrínseca con las características de las personas desaparecidas. La ausencia de correlaciones fuertes sugiere que cada variable aporta información independiente, y que un análisis multivariado

más profundo requeriría incorporar las variables categóricas mediante una codificación adecuada.

5. Limitaciones del Análisis

5.1. Calidad de los Datos

El dataset presenta limitaciones importantes en cuanto a la completitud de la información. La columna `Fecha de desaparición` concentra la mayor problemática, con 56,085 valores nulos que representan el 70.56 % de los registros. Dado que estos valores corresponden a datos faltantes no al azar (MNAR), no fue posible aplicar ningún método de imputación sin introducir sesgos graves. Por esta razón, los análisis temporales se realizaron únicamente sobre los 23,403 registros que cuentan con fecha válida, lo que limita la representatividad histórica del análisis.

La columna `Edad` presentaba 11 registros con valores mayores a 100 años —con un máximo de 1,832— y 240 registros con valor igual a cero, correspondientes a errores de captura. Estos 251 registros fueron reemplazados por `NaN` al no existir forma de recuperar el dato real.

5.2. Sesgos

- **Subregistro:** Se estima que una proporción significativa de desapariciones nunca llega a ser reportada a las autoridades, ya sea por desconfianza institucional, miedo a represalias o desconocimiento de los mecanismos de denuncia. El dataset refleja únicamente los casos que fueron reportados formalmente, por lo que no representa el universo real del fenómeno [**adonde**].

- **Sesgo por registros protegidos:** El 32.1 % de los registros originales (37,460 filas) contenía datos intencionalmente censurados bajo la etiqueta `ELIMINADO`, correspondientes a registros protegidos por la *Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados*. Su eliminación durante la limpieza implica que el dataset analizable podría no ser representativo del total de casos, especialmente si estos registros corresponden de forma desproporcionada a ciertos estados, grupos de edad o periodos temporales.

- **Heterogeneidad institucional:** La información fue capturada por múltiples autoridades federales y estatales con distintos criterios, sistemas y niveles de capacitación. Esto introduce inconsistencias en la estandarización de categorías como entidad, autoridad y nacionalidad, y puede generar diferencias en la calidad del registro entre estados.

- **Subregistro de desapariciones de mujeres:** Aunque los hombres representan el 75.6 % de los registros, las desapariciones de mujeres pueden estar subregistradas

debido a patrones culturales que desincentivan la denuncia, particularmente en casos de violencia de género o trata de personas.

5.3. Variables Faltantes

El dataset público analizado contiene únicamente 11 de las 450 variables que conforman el RNPDNO completo [**rnpdno**]. Entre las variables ausentes que enriquecerían considerablemente el análisis se encuentran: municipio de desaparición, delito asociado al caso, estatus de localización (localizado / no localizado), fecha de reporte, y características físicas de la persona. La ausencia de estas variables impide construir perfiles de riesgo más detallados y limita la profundidad de cualquier modelo predictivo.

5.4. Decisiones de Limpieza

- Los 37,460 registros con etiquetas `ELIMINADO` fueron **eliminados** del dataset de trabajo al no contener información utilizable para el análisis.
- La columna `Fecha de desaparición` **no fue imputada** debido a que los valores faltantes son MNAR y representan el 70.56 % de los registros. Los análisis temporales se realizaron exclusivamente sobre el subconjunto con fecha válida.
- La columna `Edad` fue convertida a tipo numérico con `errors='coerce'`, reemplazando valores no convertibles por `NaN`. Los valores fuera del rango válido (0 y mayores a 100) también fueron reemplazados por `NaN`.
- Se aplicó *forward fill* a la columna `Consecutivo Reportes por Persona` para propagar el identificador de persona hacia los reportes adicionales que lo tenían en blanco.
- Se normalizaron variantes ortográficas en la columna `Nacionalidad`: `HONDUREÑAO` → `HONDUREÑA`, `SALVADORENA` → `SALVADOREÑA`, `BRASILENA` → `BRASILEÑA`, `BELICENA` → `BELICEÑA`.
- Se verificó la ausencia de fechas futuras posteriores a 2024. Los 373 registros con fechas anteriores a 1990 fueron **conservados** por considerarse históricamente válidos, correspondientes a desapariciones ocurridas durante la guerra sucia en México en la década de 1970.

6. Conclusión

El análisis exploratorio del dataset `RNPDNO-22-08-2023.csv` permitió identificar patrones claros en el fenómeno de las desapariciones en México a partir de 79,488 registros con datos utilizables. Los hallazgos principales pueden resumirse en tres dimensiones:

Dimensión geográfica. Las desapariciones no se distribuyen de forma uniforme en el territorio nacional. Tamaulipas concentra el mayor número de reportes (11,288 casos), seguido por el Estado de México (8,900) y Veracruz (6,022). El coeficiente de Gini de 0.54 confirma una concentración moderada-alta en pocas entidades federativas, lo que tiene implicaciones directas para la asignación de recursos de búsqueda y el diseño de políticas públicas focalizadas.

Dimensión demográfica. Los hombres jóvenes constituyen el grupo más afectado: el 75.6 % de los registros corresponde a hombres y los jóvenes de entre 15 y 30 años representan el 45.4 % del total. La moda de 16 años señala que la adolescencia tardía es el punto de mayor frecuencia de desaparición, lo que apunta a la necesidad de políticas de prevención focalizadas en este grupo etario. La desviación estándar de 15.09 años y el coeficiente de variación del 47.5 % confirman que, si bien el fenómeno afecta a todos los grupos de edad, existe una concentración clara en la población joven.

Dimensión temporal e institucional. Se observa un incremento sostenido en el número de reportes a partir de 2006, con un pico en 2019 (2,462 casos). Las procuradurías y fiscalías estatales concentran la mayor parte de los reportes, lo que subraya la importancia de fortalecer las capacidades institucionales a nivel local.

Sin embargo, la magnitud real del problema es mayor a la que los datos reflejan. El subregistro, la eliminación del 32.1 % de registros protegidos y la ausencia de fecha en el 70.56 % de los casos son limitaciones estructurales que deben considerarse al interpretar cualquier hallazgo. El dataset representa una fotografía parcial de una crisis humanitaria de largo aliento que, según cifras del propio RNPDNO, supera los 100,000 casos acumulados.

Este análisis sienta las bases para estudios más profundos que incorporen las 450 variables del registro completo, modelos de series de tiempo para proyecciones futuras y análisis geoespaciales a nivel municipal. La disponibilidad de datos abiertos sobre este tema es un paso fundamental hacia la transparencia y la rendición de cuentas en materia de búsqueda de personas desaparecidas en México.

Referencias

[1] *Challenge validation.* URL: https://www.gob.mx/agn/articulos/el-ejercito-mexicano-durante-la-guerra-sucia.

[2] *Planificación de proyectos de AA.* URL: https://developers.google.com/machine-learning/managing-ml-projects/planning?hl=es-419.

[3] Jose Antonio Rodriguez Serrano. *Acelerar el flujo de trabajo en Ciencia de Datos.* Mayo de 2025. URL: https://www.bbvaaifactory.com/es/accelerating-data-science-workflows/.

[4] Martin Tingley et al. *Experimentation is a major focus of Data Science across Netflix.* Ene. de 2022. URL: https://netflixtechblog.com/experimentation-is-a-major-focus-of-data-science-across-netflix-f67923f8e985.